

probability space를 정보의 관점에서 다시 보기

지난 시간의 probability space $(\Omega, \mathcal{F}, P)$ 부터 다시 보자. 세 기호가 서로 다른 일을 한다. Ω 는 가능한 결과들을 모으고, sigma-field $\mathcal{F}$ 는 그 결과에 관해 물을 수 있는 사건들을 모은다. P 는 그렇게 고른 각 사건에 0과 1 사이의 확률을 붙인다.

sigma-field를 정보로 해석하면 그 정의도 자연스럽게 보인다. 사건 A 가 일어났는지 알면 A^c 가 일어났는지도 알 수 있다. 사건열 각각의 발생 여부를 알면 그중 적어도 하나가 일어났는지도 판단할 수 있다. 그래서 여집합과 countable union에 대해 닫혀 있도록 요구한다. $\mathcal{F}$ 는 우리가 결과에 관해 어떤 질문에 답할 수 있는지를 나타낸다.

density와 점프: 지난 distribution function 계산의 마무리

absolutely continuous distribution에서는 음이 아닌 Borel measurable 함수인 density f_ξ 가 있어서

$$P(\xi \in B) = \int_B f_\xi(x) dx, \quad F_\xi(x) = \int_{-\infty}^x f_\xi(t) dt$$

로 계산한다. $B = \mathbb{R}$ 를 대입하면 density의 적분은 1이므로 f_ξ 는 integrable하다. 그러나 integrable하다는 말과 연속이라는 말은 다르다. Exercise 1.5의 모든 점에서의 등식 $F'_\xi = f_\xi$ 에는 density의 연속성이라는 추가 조건이 있었다.

이제 Exercise 1.6의 discrete distribution을 보자. 서로 다른 값 x_i 들이 전체 확률을 담고 있을 때,

$$P(\xi \in B) = \sum_{i: x_i \in B} P(\xi = x_i)$$

이다. 값의 개수는 유한할 수도, countably infinite일 수도 있다. 이 distribution에서 $P(\xi = x_i) > 0$ 인 한 점은 probability mass를 담은 atom이라고 생각할 수 있다.

Exercise 1.6의 증명 $s < t$ 를 고정하면 $\{\xi \leq t\}$ 는 서로소인 두 사건 $\{\xi \leq s\}$ 와 $\{s < \xi \leq t\}$ 로 나뉜다. 따라서

$$F_\xi(t) - F_\xi(s) = P(s < \xi \leq t) = \sum_{i: s < x_i \leq t} P(\xi = x_i).$$

오른쪽 끝 t 는 포함되고 왼쪽 끝 s 는 제외된다. 구간 $(s, t]$ 안에 양의 질량이 없다면 이 차이는 0이다.

이제 $s_m \uparrow x_i$ 이고 $s_m < x_i$ 인 수열을 잡는다. 그러면 $\{\xi \leq s_m\} \uparrow \{\xi < x_i\}$ 이므로 확률의 연속성에 의해

$$F_\xi(x_i-) = P(\xi < x_i).$$

결국

$$F_\xi(x_i) - F_\xi(x_i-) = P(\xi \leq x_i) - P(\xi < x_i) = P(\xi = x_i)$$

이다. □

즉, x_i 직전까지 누적한 확률에 그 점의 질량이 추가되는 만큼 함수가 쏠린다. density를 적분하는 경우와 point mass를 더하는 경우의 차이를 이 두 계산에서 볼 수 있다. discrete distribution이라고 해서 반드시 서로 떨어진 유한 개의 점만 생각할 필요는 없다. 방금 계산은 유한하거나 countable한 값의 모임에도 적용된다.

여러 관측량을 함께 다루는 joint distribution

지금까지는 random variable 하나의 distribution을 보았다. 실제로는 여러 수치를 동시에 관측할 수도 있다. 이때는 한 실수 대신 실수의 순서쌍이나 순서 있는 묶음이 관측값이 된다.

Definition (joint distribution). 같은 probability space 위의 random variable $\xi_1, \dots, \xi_n$ 의 joint distribution은

$$P_{\xi_1, \dots, \xi_n}(B) = P((\xi_1, \dots, \xi_n) \in B), \quad B \in \mathcal{B}(\mathbb{R}^n)$$

로 정의되는 $\mathbb{R}^n$ 위의 probability measure이다.

참자가 길어졌지만 정의의 방식은 같다. $\mathbb{R}^n$ 의 Borel set을 잡고, 관측한 묶음이 그 안에 들어가는 원래 결과들의 확률을 계산한다. 이 정의 자체에는 random variable들의 independence나 density의 존재를 가정하지 않는다.

expectation은 probability measure에 대한 적분이다

Definition (integrability와 expectation). random variable ξ 에 대하여

$$\xi \in L^1(\Omega, \mathcal{F}, P) \iff \int_{\Omega} |\xi| dP < \infty$$

로 쓴다. 이때

$$E(\xi) = \int_{\Omega} \xi dP$$

를 ξ 의 expectation이라고 한다.

ξ 에는 양수와 음수가 모두 나올 수 있다. 그 적분이 유한한 실수로 잘 정의되도록 절댓값의 적분이 유한하다는 조건을 둔다. 이 조건이면 양의 부분과 음의 부분의 적분이 모두 유한하므로 무한대끼리 빼는 문제가 생기지 않는다. 또

$$|E(\xi)| \leq E(|\xi|) < \infty$$

이다. random variable은 함수이지만, 그 expectation은 적분을 마친 하나의 실수이다.

Example: indicator function과 simple function. 사건 $A \in \mathcal{F}$ 의 indicator function은

$$\mathbb{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A \end{cases}$$

이다. 사건의 발생 여부를 1과 0으로 나타내는 random variable이다. $P(A) \leq 1$ 이므로 항상 integrable하고,

$$E(\mathbb{1}_A) = \int_{\Omega} \mathbb{1}_A dP = \int_A 1 dP = P(A)$$

이다. 일반적인 measure에서는 indicator function의 integrability에 집합의 유한 measure가 필요하지만, probability space에서는 자동으로 만족된다.

서로소인 사건 $A_1, \dots, A_n$ 과 실수 a_i 로 만든 simple function

$$\eta = \sum_{i=1}^n a_i \mathbb{1}_{A_i}$$

의 경우에는 적분의 linearity에 의해

$$E(\eta) = \sum_{i=1}^n a_i P(A_i).$$

각 구역에서 갖는 값에 그 구역의 확률을 곱해서 더한다. 유한 개의 값을 갖는 이러한 함수를 여기서 step function이라고도 부른다.

distribution만 알고 expectation을 계산하는 방법

실제 문제에서는 $\omega \mapsto \xi(\omega)$ 의 구체적인 모습은 모르고 ξ 의 distribution만 아는 경우가 많다. 그래도 $h(\xi)$ 의 expectation을 구할 수 있을까? 다음 공식이 그 일을 해 준다.

Exercise 1.7: LOTUS. Borel measurable function $h : \mathbb{R} \rightarrow \mathbb{R}$ 에 대해 $h(\xi) \in L^1$ 이면

$$E(h(\xi)) = \int_{\mathbb{R}} h(x) dP_{\xi}(x).$$

이를 law of the unconscious statistician, 줄여서 LOTUS라고 부른다. 특히

$$E(h(\xi)) = \begin{cases} \int_{\mathbb{R}} h(x) f_{\xi}(x) dx, & \text{density } f_{\xi} \text{가 있을 때,} \\ \sum_i h(x_i) P(\xi = x_i), & \text{discrete distribution일 때} \end{cases}$$

이다.

왼쪽은 Ω 위의 함수 $h \circ \xi$ 를 P 로 적분하고, 오른쪽은 실수축 위의 함수 h 를 distribution P_{ξ} 로 적분한다. 따라서 변환된 random variable $h(\xi)$ 의 distribution을 먼저 구하지 않아도 된다. 필요한 가정은 $h(\xi)$ 의 integrability이지, ξ 의 integrability를 별도로 요구하는 것이 아니다. density가 존재할 때 쓰는 첫 계산식에도 density의 연속성은 필요하지 않다.

증명의 방법은 indicator function에서 시작하여 일반 함수로 넓혀 가는 것이다. 먼저 $h = \mathbb{1}_B$ 이면

$$E(\mathbb{1}_B(\xi)) = P(\xi \in B) = P_{\xi}(B) = \int_{\mathbb{R}} \mathbb{1}_B dP_{\xi}$$

이므로 정의에서 바로 성립한다. indicator function의 유한 linear combination에도 적분의 linearity로 성립한다. 음이 아닌 Borel function은 아래에서 증가하는 음이 아닌 simple function들로 근사할 수 있고, 이때 적분도 극한으로 수렴한다는 monotone convergence theorem을 적용한다. 마지막으로 일반적인 h 는 양의 부분과 음의 부분으로 나눈다. $h(\xi)$ 의 absolute integrability 덕분에 양쪽 적분이 유한하여 뺄 수 있다. 근사를 만드는 전체 과정은 여기서 전개하지 않지만, 어느 단계에서 어떤 극한을 쓰는지 기억해 두자.

variance를 정의하기 전에 확인할 것

평균으로부터 얼마나 떨어져 있는지를 제공하여 평균내면 variance가 된다. 하지만 ξ 를 적분할 수 있다고 해서 ξ^2 도 적분할 수 있는 것은 아니다.

Definition (L^2 와 variance).

$$\xi \in L^2(\Omega, \mathcal{F}, P) \iff E(\xi^2) < \infty.$$

이때 variance는

$$\text{var}(\xi) = E((\xi - E(\xi))^2) = E(\xi^2) - (E(\xi))^2$$

로 정의한다.

$m = E(\xi)$ 가 유한하면 두 번째 등식은

$$E(\xi^2 - 2m\xi + m^2) = E(\xi^2) - 2mE(\xi) + m^2 = E(\xi^2) - m^2$$

라는 전개이다. 여기서 m 은 random variable이 아니라 상수이고, 상수의 expectation은 그 상수이다.

여기서 한 가지를 먼저 확인해야 한다. L^2 라는 가정만으로 $m = E(\xi)$ 가 유한하다고 말할 수 있을까? probability space에서는 $L^2 \subset L^1$ 이므로 가능하다. 다음 부등식으로 이 포함관계를 확인하면, 방금 쓴 variance의 모든 항이 잘 정의된다는 점도 함께 해결된다.

Cauchy–Schwarz: 곱의 적분과 두 번째 moment

Exercise 1.8: Cauchy–Schwarz. $\xi, \eta \in L^2$ 이면

$$|E(\xi\eta)|^2 \leq E(\xi^2)E(\eta^2).$$

특히 $E(|\xi|) \leq \sqrt{E(\xi^2)}$ 이므로 $L^2 \subset L^1$ 이다.

Proof. 먼저 왼쪽의 expectation이 정의되는지 확인해야 한다. 실수의 제곱이 음이 아니므로

$$2|\xi\eta| \leq \xi^2 + \eta^2.$$

양변을 적분하면 오른쪽이 유한하여 $\xi\eta \in L^1$ 이다. 이 계산은 곱의 integrability를 보일 뿐, 아직 원하는 Cauchy–Schwarz 부등식을 주지는 않는다.

더 정확한 부등식을 얻기 위해 실수 t 에 대한 함수

$$q(t) = E((\xi - t\eta)^2) = E(\xi^2) - 2tE(\xi\eta) + t^2E(\eta^2)$$

를 보자. 제곱의 적분이므로 모든 t 에서 $q(t) \geq 0$ 이다. $E(\eta^2) > 0$ 이면 이 이차식의 판별식이 양수일 수 없으므로

$$4(E(\xi\eta))^2 - 4E(\xi^2)E(\eta^2) \leq 0$$

이다. $E(\eta^2) = 0$ 이면 q 는 일차 이하의 식이다. 모든 실수 t 에서 음이 아니려면 일차항의 계수도 0이어야 하므로 같은 결론을 얻는다.

마지막으로 ξ 대신 $|\xi|$, η 대신 상수함수 1을 대입하면

$$(E(|\xi|))^2 \leq E(\xi^2)E(1) = E(\xi^2).$$

제곱근을 취하면 원하는 포함관계가 나온다. □

이 포함관계에서 전체 공간의 크기를 사용했다. 일반적인 유한 measure μ 라면 오른쪽에 $\sqrt{\mu(\Omega)}$ 라는 인자가 더 붙는다. 반면 실수 전체의 Lebesgue measure는 무한하므로 같은 논리로 $L^2(\mathbb{R}) \subset L^1(\mathbb{R})$ 라고 말할 수 없다. 전체 크기가 정확히 1인 것은 지금 부등식의 상수에 영향을 주며, 포함 관계에는 전체 measure의 유한성이 핵심이다. 다른 L^p 사이의 관계도 관심이 있으면 따로 살펴볼 만하다.

tail probability를 적분하여 두 번째 moment 구하기

Exercise 1.9: tail integral formula. 음이 아닌 random variable η 에 대해

$$E(\eta^2) = 2 \int_0^\infty tP(\eta > t) dt.$$

양변이 무한대인 경우도 허용하는 음이 아닌 적분의 등식이다.

앞에서는 유한한 expectation을 위해 L^1 을 가정했다. 여기서는 음이 아닌 함수의 적분이므로 $+\infty$ 도 허용할 수 있다. 양의 무한대와 음의 무한대를 빼는 상황이 아니기 때문이다. 이 공식을 쓰기 전에 $E(\eta^2) < \infty$ 를 가정할 필요는 없다.

Proof. 먼저 결과 ω 를 하나 고정해 보자. $a = \eta(\omega)$ 는 이제 음이 아닌 실수이다. 따라서

$$\int_0^\infty 2t\mathbb{1}_{\{a>t\}} dt = \int_0^a 2t dt = a^2.$$

a 이전에는 indicator function이 1이고 이후에는 0이다. 경계 한 점은 적분에 영향을 주지 않는다. 즉, 각각의 ω 에서

$$\eta(\omega)^2 = \int_0^\infty 2t\mathbb{1}_{\{\eta(\omega)>t\}} dt$$

라는 점별 등식이 성립한다.

이제 expectation을 취하면 ω 와 t 에 대한 이중적분이 된다. 여기서 쓰는 **Tonelli's theorem**은 음이 아닌 measurable function의 반복적분 순서를 바꿀 수 있다는 정리이다. 현재 P 는 유한 measure이고 dt 는 $[0, \infty)$ 위의 Lebesgue measure이다. η 가 measurable이므로 $\{(\omega, t) : t < \eta(\omega)\}$ 도 measurable이며, 적분함수는 음이 아니다. 따라서

$$\begin{aligned} E(\eta^2) &= \int_{\Omega} \int_0^{\infty} 2t \mathbb{1}_{\{\eta > t\}} dt dP \\ &= \int_0^{\infty} 2t \left(\int_{\Omega} \mathbb{1}_{\{\eta > t\}} dP \right) dt \\ &= 2 \int_0^{\infty} t P(\eta > t) dt. \end{aligned}$$

마지막 줄에서는 indicator function의 expectation이 그 사건의 확률이라는 계산을 사용했다. $\square$

이것을 coarea formula의 확률적 형태로 볼 수 있다. η^2 를 직접 적분하는 대신, 각각의 높이 t 를 넘을 확률을 모아 같은 양을 계산한다. 교재의 긴 풀이 대신 적분 순서 교환을 사용하면 이처럼 짧아진다. 더 일반적으로 $p > 0$ 이면 같은 방법으로

$$E(\eta^p) = p \int_0^{\infty} t^{p-1} P(\eta > t) dt$$

를 얻는다. 지금은 제곱의 경우를 중심으로 기억하자. 이 공식은 뒤의 4장에서 최대값에 관한 L^2 부등식을 다룰 때 다시 사용하게 된다.

1.3 conditional probability와 independence

새 정보를 얻으면 확률을 어떻게 바꿀까?

Definition (conditional probability). 사건 $A, B \in \mathcal{F}$ 와 $P(B) > 0$ 에 대해

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

를 B 가 주어졌을 때 A 의 conditional probability라고 한다.

B 가 일어났다고 알게 되면 고려할 결과들은 B 안에 있다. 따라서 A 에서도 B 안에 있는 부분 $A \cap B$ 만 남기고, 남은 전체인 B 의 확률이 1이 되도록 $P(B)$ 로 나눈다. 교집합은 정보를 반영해 범위를 제한하고, 분모는 다시 정규화하는 역할을 한다.

분모 때문에 $P(B) > 0$ 이 필요하다. 또 조건의 방향을 바꾸면 다른 질문이 된다. 일반적으로

$$P(A | B) \neq P(B | A)$$

이며, 두 식을 모두 정의하려면 각각의 분모가 양수여야 한다. 두 식의 분자는 같아도 분모는 다르다.

sample space를 나누어 확률을 계산하기

Exercise 1.10: law of total probability. 서로소인 사건 $B_1, B_2, \dots$ 가 $\bigcup_n B_n = \Omega$ 를 만족하고 $P(B_n) > 0$ 이면

$$P(A) = \sum_{n \geq 1} P(A | B_n) P(B_n).$$

전체 결과를 서로 겹치지 않는 경우들로 나누었다. 각 경우 안에서의 확률을 구하고 그 경우 자체의 확률로 가중하여 더하는 것이다.

Proof. $A = \bigcup_n (A \cap B_n)$ 이고 이 합집합은 서로소이다. 그러므로 countable additivity와 conditional probability의 정의를 차례로 적용하면

$$P(A) = \sum_n P(A \cap B_n) = \sum_n P(A | B_n)P(B_n)$$

이다. □

모든 B_n 이 전체를 덮는다는 조건과 서로소라는 조건이 각각 어디에 쓰였는지 확인해 보자. 이 계산에는 사건들의 independence가 필요하지 않다.

조건의 방향을 뒤집는 Bayes' formula

Remark: Bayes' rule. 위 분할 조건 아래 $P(A) > 0$ 이면

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{n \geq 1} P(A | B_n)P(B_n)}.$$

앞에서는 B_n 을 조건으로 A 를 보았다. 이번에는 A 를 알게 된 뒤 어느 B_j 에 해당하는지를 묻는다. 증명은 정의로 돌아가면 쉽다.

$$P(B_j | A) = \frac{P(A \cap B_j)}{P(A)}.$$

분자는 $P(A | B_j)P(B_j)$ 이고, 분모는 방금 얻은 law of total probability로 표현된다. 그래서 위 식을 얻는다. 짧은 대수 계산이지만, 어떤 정보를 조건으로 삼는지를 바꾸어 준다는 의미가 있다.

independence는 모든 부분모임에 대한 조건이다

이제 사건의 independence에서 시작해 random variable의 independence로, 나아가 sigma-field의 independence로 개념을 넓혀 가자.

Definition (사건들의 independence). 두 사건 A, B 가

$$P(A \cap B) = P(A)P(B)$$

를 만족하면 independent라고 한다. $A_1, \dots, A_n$ 이 independent라는 것은 모든 $1 \leq k \leq n$ 과 서로 다른 첨자 $i_1, \dots, i_k$ 에 대해

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = \prod_{j=1}^k P(A_{i_j})$$

가 성립한다는 뜻이다.

여기서는 전체 n 개를 한꺼번에 교차한 식 하나만 확인해서는 안 된다. 두 개씩 골라 확인하는 pairwise independence만으로도 부족하다. 임의의 부분모임을 골라도 곱의 등식이 성립해야 한다. 이처럼 모든 부분모임을 확인한다는 점에서 전체 모임의 independence가 더 강한 조건이다.

Exercise 1.11. $P(B) > 0$ 이면

$$A, B \text{가 independent} \iff P(A | B) = P(A).$$

실제로 $P(A \cap B)/P(B) = P(A)$ 의 양변에 $P(B)$ 를 곱하면 정의의 식이 나온다. 따라서 “ B 를 알게 되어도 A 의 확률이 바뀌지 않는다”는 해석이 정확해진다. 이것은 확률에 관한 설명이며, 별도의 인과관계를 단정하는 정의는 아니다.

random variable의 independence와 expectation의 곱

Definition (random variable들의 independence). 모든 Borel set $A, B \subset \mathbb{R}$ 에 대해

$$P(\eta \in A, \xi \in B) = P(\eta \in A)P(\xi \in B)$$

이면 random variable η, ξ 가 independent라고 한다. 유한한 모임에서는 모든 Borel set의 선택에 대해 대응하는 사건들이 independent이어야 하며, 임의의 모임에서는 모든 유한 부분모임이 independent이어야 한다.

쉽게 두 조건을 동시에 만족한다는 뜻이다. 왼쪽은 $\{\eta \in A\} \cap \{\xi \in B\}$ 의 확률이다. 이렇게 random variable의 independence를 사건들의 independence로 정의한다.

Proposition 1.1. $\xi_1, \dots, \xi_n \in L^1$ 이 independent이고 $\xi_1 \cdots \xi_n \in L^1$ 이면

$$E(\xi_1 \cdots \xi_n) = \prod_{i=1}^n E(\xi_i).$$

특히 independent인 $\xi, \eta \in L^2$ 에 대해서는

$$E(\xi\eta) = E(\xi)E(\eta)$$

가 성립하며, 이들을 uncorrelated라고 한다.

independence가 있으면 곱의 expectation을 각 expectation의 곱으로 분리할 수 있다. expectation 기호만 보고 언제나 이렇게 분리해도 된다고 생각해서는 안 된다. 여기서는 필요한 integrability와 independence를 함께 확인한다. 특히 L^2 인 두 변수의 경우에는 앞의 부등식에서 각 변수와 곱의 integrability를 이미 확보했다.

증명의 기본 출발점도 indicator function이다. independent인 사건들 A_i 에 대해

$$E\left(\prod_i \mathbb{1}_{A_i}\right) = P\left(\bigcap_i A_i\right) = \prod_i P(A_i) = \prod_i E(\mathbb{1}_{A_i}).$$

각 변수의 Borel function으로 만든 simple function들에는 이 식과 linearity를 적용한다. 음이 아닌 변수는 증가하는 simple function으로 근사해 monotone convergence theorem을 쓰고, 부호가 있는 변수는 양의 부분과 음의 부분으로 나누어 전개한다. integrability는 마지막에 유한한 expectation들을 더하고 빼도록 해 준다. 상세한 근사 구성은 생략하지만, independence가 실제로 쓰이는 출발점은 위 사건 교집합의 확률을 곱으로 바꾸는 단계이다.