

확률론 (MAT4033)

Probability Theory (2026 Fall) – 학습용 강의노트

김민현 교수님

Contents

1. 확률의 언어	1
1.1 사건과 확률	1
1.2 random variable	7
1.3 conditional probability와 independence	15
2. conditional expectation	18
2.1 사건을 조건으로 하는 경우	18
2.2 discrete random variable을 조건으로 하는 경우	19
2.3 일반 random variable을 조건으로 하는 경우	23
2.4 sigma-field를 조건으로 하는 경우	28
2.5 일반 성질	31
3. discrete time martingale	36
3.1 random variable들의 열과 sample path	36
3.2 filtration과 지금까지의 정보	37
3.3 martingale	39
3.4 우연에 따른 게임과 전략	43

Chapter 1. 확률의 언어

이 강의에서는 해석학에서 익힌 생각을 바탕으로 확률론의 언어를 배워 나간다. 앞으로 sigma-field, probability space, random variable, distribution, expectation, variance, conditional probability, independence가 차례로 등장한다. 처음에는 이름이 많아 어렵게 느껴질 수 있다. 이럴 때는 정의를 따로 외우기보다, 어떤 질문에 답하려고 그 정의를 도입하는지 따라가 보자. 그러면 앞의 개념이 다음 개념으로 이어지는 이유를 볼 수 있다.

가령 random variable은 이름과 달리 하나의 함수이다. 가능한 결과를 입력하면 우리가 관측하려는 수치를 돌려준다. 여기에 조건 하나가 더 필요하다. 그 수치에 관한 질문을 확률로 계산할 수 있어야 한다는 것이다. 오늘은 바로 이 조건이 무엇인지까지 살펴본다. measure에 관한 용어도 그때그때 필요한 만큼 뜻을 짚어 가자.

교재는 일곱 장으로 이루어져 있고, 마지막 장에서는 Itô calculus를 다룬다. 그 내용까지 살펴보는 것이 목표이다. 지금은 먼저 이후의 논의를 가능하게 해 주는 기본 언어를 마련하자.

1.1 사건과 확률

어떤 집합에 확률을 물을 수 있을까?

먼저 가능한 결과들을 모은 비어 있지 않은 집합 Ω 를 고정하자. 그 안의 한 원소 ω 는 개별 결과이고, 부분집합 $A \subset \Omega$ 는 어떤 조건을 만족하는 결과들의 모임이다. 예를 들어 동전을 던졌을 때 앞면이 나오는 결과들만 모을 수 있다.

여기서 집합을 한 단계 더 모아야 한다. $\mathcal{P}(\Omega) = 2^\Omega$ 는 Ω 의 모든 부분집합을 원소로 갖는 **power set**이다. 그중에서 우리가 다룰 부분집합들을 골라 모은 것이 $\mathcal{F}$ 이다. 따라서

$$\omega \in \Omega, \quad A \subset \Omega, \quad A \in \mathcal{F}, \quad \mathcal{F} \subset \mathcal{P}(\Omega)$$

는 서로 다른 관계를 표현한다. $\mathcal{F}$ 의 원소는 개별 결과가 아니라 결과들의 집합이라는 점을 먼저 구별해 두자.

Definition 1.1: sigma-field. 비어 있지 않은 집합 Ω 에 대하여, 집합들의 모임 $\mathcal{F} \subset \mathcal{P}(\Omega)$ 가 다음 세 조건을 만족하면 **sigma-field** 또는 **sigma-algebra**라고 한다.

1. $\emptyset \in \mathcal{F}$.
2. $A \in \mathcal{F}$ 이면 $\Omega \setminus A \in \mathcal{F}$.
3. $A_n \in \mathcal{F}$ 가 모든 $n \geq 1$ 에 대해 성립하면 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$.

첫 조건은 단순히 $\mathcal{F}$ 가 비어 있지 않다는 말보다 구체적이다. 빈집합 자체가 $\mathcal{F}$ 의 원소여야 한다. 둘째 조건은 여집합을 취해도 $\mathcal{F}$ 안에 남아야 한다는 뜻이다. 셋째 조건에서는 집합들을 $A_1, A_2, \dots$ 처럼 자연수로 나열한 뒤 모두 합친다. 이렇게 자연수로 나열할 수 있다는 것을 countable이라고 한다. 유한 개의 합집합도 나머지 항을 빈집합으로 두면 이 조건에 포함된다.

세 조건에서 따라오는 집합 연산

정의가 길어 보이지만, 이 세 조건을 가지고 실제로 무엇을 할 수 있는지 보자.

Remark. 1. $\Omega = \Omega \setminus \emptyset$ 이므로 $\Omega \in \mathcal{F}$ 이다.

2. $A_n \in \mathcal{F}$ 이면 De Morgan's laws에 의해

$$\bigcap_{n=1}^{\infty} A_n = \Omega \setminus \bigcup_{n=1}^{\infty} (\Omega \setminus A_n) \in \mathcal{F}.$$

각 여집합이 $\mathcal{F}$ 에 속하고, 그 countable union도 속하며, 마지막으로 다시 여집합을 취할 수 있기 때문이다.

3. $A, B \in \mathcal{F}$ 이면

$$A \setminus B = A \cap (\Omega \setminus B) \in \mathcal{F}.$$

즉, sigma-field는 여집합, countable union, countable intersection 같은 기본 집합 연산을 해도 닫혀 있는 집합들의 모임이다. 다만 모든 부분집합을 반드시 포함해야 하는 것은 아니다. 바로 이 점이 다음 예에서 중요하다.

실수 위에서 만나는 sigma-field

Example: 실수 위의 세 가지 집합들의 모임. 가장 쉬운 예는 power set $\mathcal{P}(\mathbb{R})$ 이다. 실수의 부분집합들을 어떤 식으로 합치거나 여집합을 취해도 결과는 실수의 부분집합이므로 sigma-field의 조건을 만족한다.

두 번째는 **Borel sigma-field** $\mathcal{B}(\mathbb{R})$ 이다. 이는 실수의 모든 열린집합을 포함하는 가장 작은 sigma-field이며, 그 원소를 **Borel set**이라고 한다. 여기서 “가장 작다”는 말은, 열린집합들을 포함하는 다른 어떤 sigma-field 안에도 $\mathcal{B}(\mathbb{R})$ 가 포함된다는 뜻이다.

모든 열린구간을 포함하는 가장 작은 sigma-field라고 정의해도 같다. 실수의 열린집합은 열린구간들의 countable union으로 쓸 수 있기 때문이다. 그렇다고 열린집합 하나하나가 모두 구간이라는 뜻은 아니다. 예를 들어 $(0, 1) \cup (2, 3)$ 도 열린집합이다.

세 번째는 Lebesgue measurable set 전체의 모임 $\mathcal{M}(\mathbb{R})$ 이다. 이것도 sigma-field이며, Lebesgue measure가 정의되는 집합들을 모은 것이다.

Lebesgue measure는 구간의 길이를 더 일반적인 집합으로 확장한 measure이다. 익숙한 식으로 $\text{Leb}([a, b]) = b - a$ 이다. 그런데 그 measure를 실수의 모든 부분집합에 그대로 정의할 수는 없다. 그래서 전체 power set보다 작은, measure를 정의할 수 있는 집합들의 모임을 사용한다. 여기서는 그러한 집합을 구성하는 이론까지 들어가기보다

$$\mathcal{B}(\mathbb{R}) \subset \mathcal{M}(\mathbb{R}) \subset \mathcal{P}(\mathbb{R})$$

라는 관계와, 어떤 집합들의 모임을 measure의 정의역으로 선택하는지에 주목하자.

동전 두 번 던지기: 같은 결과 공간, 다른 정보

Example: 첫 번째 동전만 관측하는 경우. 두 동전을 던지거나 동전 하나를 두 번 던진 결과를

$$\Omega = \{HH, HT, TH, TT\}$$

로 나타내자. H 는 앞면, T 는 뒷면이고 순서도 구별한다. 예를 들어 HT 는 첫 번째가 앞면이고 두 번째가 뒷면인 결과이다.

이제 첫 번째 동전만 볼 수 있다고 하자. 첫 번째가 앞면인 사건은

$$A = \{HH, HT\},$$

뒷면인 사건은 $A^c = \{TH, TT\}$ 이다. 첫 번째 동전을 관측하면 어느 쪽에 속하는지는 알 수 있지만, HH 와 HT 중 어느 결과인지는 구별하지 못한다. 따라서 이 관측으로 얻는 정보는

$$\mathcal{F} = \{\emptyset, A, A^c, \Omega\}$$

로 나타낼 수 있다. 여집합을 취하면 A 와 A^c 가 바뀌고, 둘을 합치면 Ω 가 되므로 sigma-field의 조건도 확인된다.

반면 두 번째 동전이 앞면인 사건

$$B = \{HH, TH\}$$

는 이 $\mathcal{F}$ 에 속하지 않는다. 첫 번째 동전만 보아서 그 사건이 일어났는지 판단할 수 없기 때문이다.

같은 Ω 에서도 전체 power set을 선택할 수도 있고, 이처럼 더 작은 sigma-field를 선택할 수도 있다. 네 원소를 가진 Ω 의 power set에는 $2^4 = 16$ 개의 원소가 있지만, 위의 $\mathcal{F}$ 에는 네 개만 있다. sigma-field를 선택하는 일은 우리가 어떤 정보를 다룰 것인지와 연결된다. 이 관점은 뒤에서 random variable이 만들어 내는 정보와 conditional expectation을 이해할 때 다시 쓰인다.

사건에 수치를 붙이는 probability measure

이제 어떤 부분집합들을 사건으로 다룰지 정했다. 다음에는 그 사건에 확률이라는 수치를 붙여야 한다.

Definition 1.2: probability measure와 probability space. sigma-field $\mathcal{F}$ 위의 함수

$$P : \mathcal{F} \longrightarrow [0, 1]$$

가 다음 조건을 만족하면 probability measure라고 한다.

1. $P(\Omega) = 1$.
2. 서로소인 사건들 $A_1, A_2, \dots \in \mathcal{F}$ 에 대하여

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n).$$

둘째 성질을 **countable additivity**라고 한다. Ω 를 **sample space**, $\mathcal{F}$ 를 **event space**, 그 원소 $A \in \mathcal{F}$ 를 **사건**이라고 한다. 세 가지를 함께 모은 $(\Omega, \mathcal{F}, P)$ 를 **probability space**라고 한다.

서로소라는 조건은 서로 다른 m, n 에 대해 $A_m \cap A_n = \emptyset$ 이라는 뜻이다. 동시에 일어날 수 없는 사건들을 합칠 때는 확률을 그대로 더한다. 겹치는 부분이 있다면 같은 결과를 중복해서 세므로 이 등식을 그대로 사용할 수 없다.

일반적인 measure는 집합에 음이 아닌 크기를 부여하며 countable additivity를 만족하는 함수이다. probability measure는 그중에서도 전체 공간의 크기가 정확히 1인 경우이다. Lebesgue measure가 길이를 준다면, probability measure는 사건의 확률을 준다. P 가 받아들이는 것은 결과 ω 가 아니라 사건 A 라는 점도 구별해 두자.

확률이 1이라는 말과 모든 결과에서 성립한다는 말

Example: 단위구간 위의 확률.

$$\Omega = [0, 1], \quad \mathcal{F} = \mathcal{B}([0, 1]), \quad P(A) = \text{Leb}(A) \quad (A \in \mathcal{F})$$

로 두자. $\mathcal{B}([0, 1])$ 는 Borel set을 단위구간에 제한한 집합들의 모임이다. Lebesgue measure를 이 집합들의 모임에 제한해도 countable additivity가 유지되고,

$$P(\Omega) = \text{Leb}([0, 1]) = 1$$

이므로 probability space가 된다. 구간 $[a, b] \subset [0, 1]$ 에 대해서는

$$P([a, b]) = b - a$$

이다. 이 예에서는 길이가 곧 확률이다.

단위구간에서 한 점을 빼면 어떻게 될까? 한 점의 Lebesgue measure는 0이므로

$$A = [0, 1] \setminus \{1/2\} \implies P(A) = 1, \quad A \neq \Omega.$$

실제로 제외된 결과가 있지만, 그 예외들의 확률은 0이다.

Definition (almost sure 성립). 사건 A 가 $P(A) = 1$ 을 만족하면 A 가 **almost surely** 성립한다고 하고, almost surely를 줄여 a.s.라고 쓴다.

따라서 “모든 $\omega \in \Omega$ 에서 성립한다”와 “almost surely 성립한다”는 다른 말이다. 후자는 예외가 있더라도 그 예외의 확률이 0이면 된다. 확률 1을 집합 자체가 Ω 라는 말로 바꾸어 읽지 말자.

probability measure의 기본 계산 규칙

Remark: 여사건, **monotonicity**, **countable subadditivity**. probability space에서 다음이 성립한다.

1. $P(\Omega) = 1, P(\emptyset) = 0$.
2. $P(A^c) = 1 - P(A)$.
3. $A \subset B$ 이면 $P(A) \leq P(B)$.
4. 임의의 사건열에 대해

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n).$$

마지막 성질을 **countable subadditivity**라고 한다.

이 성질들이 정의와 어떻게 연결되는지 짚어 보자. Ω 와 빈집합들을 서로소 합집합으로 놓고 countable additivity를 적용하면 빈집합의 확률은 0이어야 한다. 또 $\Omega = A \cup A^c$ 는 서로소 합집합이므로 $1 = P(A) + P(A^c)$ 이다.

$A \subset B$ 일 때는 $B = A \cup (B \setminus A)$ 로 나눌 수 있다. 따라서

$$P(B) = P(A) + P(B \setminus A) \geq P(A)$$

이어서 monotonicity를 얻는다.

마지막 부등식에서는 겹치는 부분을 제거해 보면 된다. $C_1 = A_1$,

$$C_n = A_n \setminus \bigcup_{k < n} A_k \quad (n \geq 2)$$

로 두면 C_n 들은 서로소이고, 전체 합집합은 원래와 같다. 이미 앞에서 센 부분을 다음 집합에서 빼는 것이다. 그러므로

$$P\left(\bigcup_n A_n\right) = P\left(\bigcup_n C_n\right) = \sum_n P(C_n) \leq \sum_n P(A_n).$$

additivity는 서로소라는 조건 아래의 등식이고, subadditivity는 그 조건 없이 쓸 수 있는 부등식이다.

집합의 극한을 확률의 극한으로 옮기기

실수열의 극한은 익숙하지만, 집합열의 극한이라는 말은 어떤 뜻인가? 여기서는 다음 두 경우를 사용한다.

$$\begin{aligned} A_n \nearrow A &\iff A_n \subset A_{n+1}, \quad \bigcup_{n=1}^{\infty} A_n = A, \\ A_n \searrow A &\iff A_n \supset A_{n+1}, \quad \bigcap_{n=1}^{\infty} A_n = A. \end{aligned}$$

첫째는 집합들이 커지면서 A 를 채워 가는 경우이고, 둘째는 작아지면서 최종적으로 남는 부분이 A 인 경우이다.

Exercise 1.1: 확률의 연속성. 모든 n 에 대해 $A_n \in \mathcal{F}$ 라 하자.

1. $A_n \nearrow A$ 이면 $P(A_n) \nearrow P(A)$.
2. $A_n \searrow A$ 이면 $P(A_n) \searrow P(A)$.

왼쪽은 집합의 포함관계와 합집합 또는 교집합에 관한 말이다. 오른쪽은 $[0, 1]$ 안의 실수열에 관한 말이다. 이 성질이 두 종류의 극한을 이어 준다.

Proof. 증가하는 경우, 처음부터 있던 부분과 매 단계 새로 들어오는 부분으로 나누자.

$$D_1 = A_1, \quad D_n = A_n \setminus A_{n-1} \quad (n \geq 2).$$

이들은 서로소이고 $A_n = \bigcup_{k=1}^n D_k$, $A = \bigcup_{k=1}^{\infty} D_k$ 이므로

$$P(A_n) = \sum_{k=1}^n P(D_k) \longrightarrow \sum_{k=1}^{\infty} P(D_k) = P(A).$$

무한합으로 넘어가는 근거는 countable additivity이다.

감소하는 경우에는 $A_n^c \nearrow A^c$ 에 방금 얻은 결과를 적용한다. 그러면 $P(A_n^c) \rightarrow P(A^c)$ 이고,

$$P(A_n) = 1 - P(A_n^c) \longrightarrow 1 - P(A^c) = P(A)$$

이다. 각각의 monotonicity도 집합의 포함관계에서 따라온다. □

해석학에서 Lebesgue measure m 에 대해 만나는 대응 명제는 다음과 같다.

Corollary 3.3: measure의 연속성. measurable set의 열 E_n 에 대해 $E_n \nearrow E$ 이면 $m(E_n) \rightarrow m(E)$ 이다. $E_n \searrow E$ 인 경우에는 어떤 k 에 대해 $m(E_k) < \infty$ 라는 조건 아래 $m(E_n) \rightarrow m(E)$ 이다.

확률에서는 왜 감소하는 경우에 유한성 조건을 따로 쓰지 않을까? 모든 사건에 대해 $P(A_n) \leq P(\Omega) = 1$ 이므로 이미 만족되기 때문이다. countable additivity에서 위 증명을 직접 다시 만들어 보는 것이 좋은 연습이다. 먼저 스스로 시도하고, 막히면 교재의 장 끝에 있는 해답과 비교해 보자.

Borel–Cantelli: 합이 유한하면 무한히 자주 일어나지 않는다

다음 lemma는 확률들의 합에 관한 정보를 almost sure 성립에 관한 정보로 바꾸어 준다. 먼저 사건열 $A_1, A_2, \dots$ 에 대해

$$B_n = \bigcup_{k \geq n} A_k$$

로 두자. B_n 은 n 번째 이후의 사건 중 적어도 하나가 일어나는 사건이다. n 이 커지면 합칠 사건이 줄어들므로 $B_{n+1} \subset B_n$ 이다.

그렇다면 모든 B_n 에 속한다는 말은 무엇인가? 어느 n 을 정하더라도 그 이후에 일어나는 A_k 가 하나는 있다는 뜻이다. 이것은 A_k 가 무한히 많이 일어난다는 뜻과 같다. 따라서

$$\limsup_{k \rightarrow \infty} A_k = \bigcap_{n=1}^{\infty} \bigcup_{k \geq n} A_k = \{\omega : \omega \in A_k \text{인 } k \text{가 무한히 많음}\}.$$

countable union과 countable intersection으로 만들었으므로 이 집합도 사건이다.

Lemma 1.1: Borel–Cantelli. 사건열 $A_n \in \mathcal{F}$ 가

$$\sum_{n=1}^{\infty} P(A_n) < \infty$$

를 만족하면

$$P\left(\bigcap_{n=1}^{\infty} B_n\right) = P\left(\limsup_{n \rightarrow \infty} A_n\right) = 0.$$

Proof. 목표는 모든 꼬리 사건 B_n 에 남는 결과들의 확률이 0임을 보이는 것이다. countable subadditivity로

$$0 \leq P(B_n) \leq \sum_{k \geq n} P(A_k).$$

오른쪽은 수렴하는 음이 아닌 급수의 꼬리합이다. 전체 합이 유한하다는 가정 때문에 $n \rightarrow \infty$ 일 때 이 꼬리합이 0으로 간다. 따라서 $P(B_n) \rightarrow 0$ 이다.

이제 $B_n \searrow \bigcap_{n \geq 1} B_n$ 이고, 확률의 연속성에 의해

$$P\left(\bigcap_{n \geq 1} B_n\right) = \lim_{n \rightarrow \infty} P(B_n) = 0$$

을 얻는다. □

여기서 합의 첨자가 $k \geq n$ 이라는 점이 중요하다. 처음부터 n 까지 더한 부분합이 아니라, n 부터 끝까지 더한 꼬리합이 작아지는 것이다. 또 각 B_n 의 확률이 곧바로 0이라는 말도 아니다. 그 확률들이 0으로 수렴하고, 모든 꼬리에 공통으로 남는 사건의 확률이 0이라는 결론이다.

almost surely A_n 이 유한 번만 일어난다고 읽어도 같다. 다만 마지막으로 일어나는 시점은 결과 ω 마다 다를 수 있다. 이 lemma에는 사건들의 independence를 가정하지 않았다. 증명에서도 countable subadditivity와 확률의 연속성만 사용했다.

Exercise 1.6.16: Lebesgue measure에서의 Borel–Cantelli.

$\mathbb{R}^d$ 의 measurable set의 열 E_k 에 대하여 $\sum_k m(E_k) < \infty$ 이면,

$$E = \{x : x \in E_k \text{인 } k \text{가 무한히 많음}\} = \limsup_{k \rightarrow \infty} E_k$$

는 measurable set이고 $m(E) = 0$ 이다.

집합의 꼬리합을 추정한다는 생각은 여기서도 같다. 확률론에서는 그 결론을 “almost surely 유한 번만 일어난다”는 언어로 읽는 것이다. 증명은 짧지만 이후에도 반복해서 사용할 중요한 연결이다. 여기까지 집합과 확률의 관계가 정리되었다면, 이제 그 공간 위에서 무엇을 관측할지 생각해 보자.

1.2 random variable**관측값을 함수로 나타내기**

가능한 결과가 ω 로 주어졌을 때, 우리가 관심을 갖는 수치를 $\xi(\omega)$ 로 나타내자. 그러면 관측량은 함수

$$\xi : \Omega \longrightarrow \mathbb{R}$$

가 된다. 이 강의에서는 주로 실수값을 갖는 함수를 다룬다. 함수 ξ 자체와 그 함수가 한 결과에서 갖는 실현값 $\xi(\omega)$ 를 구별해 두자.

이제 관측값이 어떤 Borel set $B \subset \mathbb{R}$ 에 속할 확률을 묻고 싶다. 하지만 P 는 Ω 의 사건에만 적용할 수 있다. 그래서 관측값에 관한 질문을 원래 공간의 사건으로 되돌려야 한다.

Definition 1.3: measurable function과 random variable. 함수 $\xi : \Omega \rightarrow \mathbb{R}$ 가 모든 $B \in \mathcal{B}(\mathbb{R})$ 에 대해

$$\{\xi \in B\} := \{\omega \in \Omega : \xi(\omega) \in B\} = \xi^{-1}(B) \in \mathcal{F}$$

를 만족하면 $\mathcal{F}$ -measurable이라고 한다. probability space $(\Omega, \mathcal{F}, P)$ 위의 이러한 함수를 **random variable**이라고 한다.

measurability가 있어야 $P(\{\xi \in B\})$ 가 정의된다. 따라서 measurability는 관측값에 관한 질문을 우리가 확률을 붙일 수 있는 사건으로 바꾸어 준다는 조건이다.

$\xi^{-1}(B)$ 는 역함숫값이 아니라 **역상**이다. ξ 가 일대일일 필요도 없다. B 안으로 보내지는 모든 결과 ω 를 모으는 연산이다. 예를 들어 $\{\xi \leq x\}$ 는 숫자들의 집합이 아니라, 관측값이 x 이하인 결과들을 모은 Ω 의 부분집합이다.

연속함수의 정의와도 비교해 볼 수 있다. 연속성에서는 공역의 열린집합의 역상이 열린집합인지 확인한다. 여기서는 공역의 Borel set의 역상이 지정된 sigma-field에 들어가는지를 확인한다. 조건은 다르지만, 공역의 집합을 역상으로 가져와 함수를 조사한다는 생각은 같다. 실수값 함수의 measurability를 $\{\xi < a\}$ 같은 집합들로 검사하는 해석학의 정의도 이 관점과 연결된다.

random variable을 관측하면 어떤 정보를 얻게 될까?

random variable ξ 가 주어졌다는 것은 이미 $(\Omega, \mathcal{F}, P)$ 가 있다는 뜻이다. 그런데 그 random variable 하나를 관측해서 얻는 정보가 $\mathcal{F}$ 전체와 같을 필요는 없다. 첫 번째 동전만 보았을 때 전체 결과를 알 수 없었던 예를 떠올려 보자.

Definition 1.4: random variable이 생성하는 sigma-field.

$$\sigma(\xi) = \{\{\xi \in B\} : B \in \mathcal{B}(\mathbb{R})\}$$

를 ξ 가 생성하는 sigma-field라고 한다.

여기서는 실수의 Borel set들을 모으는 것이 아니라, 그 집합들의 역상을 모으고 있다. 그래서 $\sigma(\xi)$ 는 Ω 위의 집합들의 모임이다. ξ 의 measurability 때문에 $\sigma(\xi) \subset \mathcal{F}$ 이다.

이 집합들의 모임이 정말 sigma-field인지 확인해 보자. $\xi^{-1}(\emptyset) = \emptyset$ 이고,

$$\Omega \setminus \xi^{-1}(B) = \xi^{-1}(\mathbb{R} \setminus B), \quad \bigcup_n \xi^{-1}(B_n) = \xi^{-1}\left(\bigcup_n B_n\right).$$

Borel set들이 여집합과 countable union에 대해 닫혀 있으므로 역상들의 모임도 같은 성질을 가진다. 또 ξ 를 measurable하게 만드는 어떤 sigma-field라도 이 역상들을 모두 포함해야 한다. 따라서 $\sigma(\xi)$ 는 ξ 를 measurable하게 만드는 가장 작은 sigma-field이다.

정보의 관점에서는 $\sigma(\xi)$ 를 “ ξ 를 관측해서 알 수 있는 모든 사건”으로 해석한다. 함수값이 어느 B 에 들어갔는지를 알면 $\{\xi \in B\}$ 가 일어났는지를 알 수 있기 때문이다.

Definition 1.5: 여러 random variable이 생성하는 sigma-field. 같은 probability space 위의 random variable들의 모임 $\{\xi_i : i \in \mathcal{I}\}$ 에 대하여

$$\sigma(\xi_i : i \in \mathcal{I})$$

는 모든 $i \in \mathcal{I}$ 와 모든 $B \in \mathcal{B}(\mathbb{R})$ 에 대한 사건 $\{\xi_i \in B\}$ 를 포함하는 가장 작은 sigma-field이다. 첨자집합 $\mathcal{I}$ 는 유한할 수도, countably infinite일 수도, uncountable일 수도 있다.

여러 관측을 함께 사용하면 각 관측에 관한 질문들을 함께 다룰 수 있어야 한다. 이 경우에는 각 random variable의 역상들을 단순히 모은 집합들의 모임이 이미 sigma-field라고 가정하지 않는다. 그 사건들을 모두 포함하면서 필요한 집합 연산에 닫히도록 만든 가장 작은 sigma-field를 취한다.

관측한 값으로 만든 함수와 Doob–Dynkin lemma

Exercise 1.3. $f : \mathbb{R} \rightarrow \mathbb{R}$ 가 Borel measurable function이면 $f(\xi)$ 는 $\sigma(\xi)$ -measurable이다.

여기서 f 가 Borel measurable이라는 말은 모든 Borel set B 에 대해 $f^{-1}(B)$ 도 Borel set이라는 뜻이다. $f(\xi)$ 는 $f \circ \xi$ 를 줄여 쓴 것이며, ω 에서의 값은 $f(\xi(\omega))$ 이다.

Proof. Borel set B 를 하나 잡으면

$$\{f(\xi) \in B\} = \{\xi \in f^{-1}(B)\} = \xi^{-1}(f^{-1}(B)).$$

$f^{-1}(B)$ 가 Borel set이므로 마지막 집합은 $\sigma(\xi)$ 에 속한다. 이것이 필요한 measurability이다. $\square$

역상을 두 번 취하면 되는 짧은 증명이다. 정보의 언어로 읽으면, ξ 의 값을 알고 있을 때 그 값에 정해진 함수 f 를 적용한 결과도 알 수 있다는 뜻이다.

놀랍게도 그 역도 성립한다.

Lemma 1.2: Doob–Dynkin. 실수값 함수 η 가 $\sigma(\xi)$ -measurable이면 어떤 Borel function $f : \mathbb{R} \rightarrow \mathbb{R}$ 가 존재하여

$$\eta = f(\xi)$$

가 성립한다.

확률론에 큰 공헌을 한 Doob와 Dynkin의 이름을 딴 lemma이다. 앞의 연습문제에서는 ξ 와 f 가 이미 주어져 있었다. 여기서는 ξ 와 η 만 주어져 있고, η 가 ξ 의 정보로 measurable이라는 사실에서 함수 f 의 존재를 얻는다. 즉, ξ 를 관측해 알 수 있는 실수값 함수는 실제로 ξ 의 값에 어떤 Borel function을 적용한 형태로 표현된다.

어려운 점은 그 f 를 구성하는 것이다. 지금은 그 구성의 증명까지 들어가지 않고 명제를 사용하자. 이 명제는 주어진 $\sigma(\xi)$ 에 대한 measurability를 가정한 함수의 표현이며, 위 등식은 함수의 등식으로 제시되어 있다. 단순히 두 함수의 평균이나 distribution이 같다는 뜻은 아니다.

sample space에서 실수축으로: distribution과 distribution function

지금까지는 random variable이 어떤 sigma-field를 만드는지 보았다. 이번에는 random variable이 새로운 probability measure를 만든다는 것을 보자. 이름이 비슷해도 생성하는 대상이 다르다.

Definition 1.6: distribution과 distribution function. random variable ξ 의 **distribution**은

$$P_\xi(B) = P(\{\xi \in B\}), \quad B \in \mathcal{B}(\mathbb{R})$$

로 정의되는 $\mathbb{R}$ 위의 probability measure이다. **distribution function**은

$$F_\xi : \mathbb{R} \longrightarrow [0, 1], \quad F_\xi(x) = P_\xi((-\infty, x]) = P(\xi \leq x)$$

이다. distribution function은 cumulative distribution function이라고도 부른다.

원래 P 는 Ω 의 사건을 입력받지만, P_ξ 는 실수의 Borel set을 입력받는다. 그 집합을 ξ 의 역상으로 가져와 원래 확률 P 를 적용하는 것이다. 그래서 관측값에 관한 확률을 계산할 때는 복잡할 수 있는 sample space를 잠시 뒤로 두고 익숙한 실수축 위에서 일할 수 있다.

이것이 probability measure라는 사실도 정의와 연결해 볼 수 있다. $P_\xi(\mathbb{R}) = P(\Omega) = 1$ 이고, 서로소인 Borel set들의 역상도 서로소이므로 원래 P 의 countable additivity가 P_ξ 에 그대로 전달된다.

대상들을 나란히 놓아 보면 차이가 분명하다.

대상	입력	출력
ξ	$\omega \in \Omega$	$\xi(\omega) \in \mathbb{R}$
P	$A \in \mathcal{F}$	$P(A) \in [0, 1]$
P_ξ	$B \in \mathcal{B}(\mathbb{R})$	$P(\xi \in B) \in [0, 1]$
F_ξ	$x \in \mathbb{R}$	$P(\xi \leq x) \in [0, 1]$

특히 distribution은 집합에 확률을 주는 measure이고, distribution function은 실수 x 까지 쌓인 확률을 주는 함수이다. x 는 여기서 누적할 범위를 정하는 문턱값이며, random variable ξ 자체와도 다르다.

distribution function은 왜 오른쪽에서 연속일까?

Exercise 1.4. distribution function F_ξ 는 감소하지 않고 오른쪽에서 연속이며,

$$\lim_{x \rightarrow -\infty} F_\xi(x) = 0, \quad \lim_{x \rightarrow \infty} F_\xi(x) = 1$$

을 만족한다.

Proof. 먼저 $x \leq y$ 이면 $\{\xi \leq x\} \subset \{\xi \leq y\}$ 이므로 확률의 monotonicity에 의해 $F_\xi(x) \leq F_\xi(y)$ 이다. 문턱값을 오른쪽으로 옮기면 더 많은 관측값을 포함하므로 누적확률은 줄어들지 않는다.

오른쪽 연속성을 보이려면 $x_n \searrow x$ 를 잡는다. 실수축에서 x_n 이 x 의 오른쪽에서 내려오는 모습을 생각해 보자. 그러면

$$\{\xi \leq x_n\} \searrow \{\xi \leq x\}.$$

실제로 $\xi(\omega) \leq x$ 이면 모든 x_n 이하이다. 반대로 $\xi(\omega) > x$ 이면 충분히 큰 n 에서는 $x_n < \xi(\omega)$ 가 되어 그 사건에서 빠진다. 따라서 교집합은 정확히 $\{\xi \leq x\}$ 이다. 이제 감소하는 사건열에 대한 확률의 연속성을 쓰면

$$F_\xi(x_n) = P(\xi \leq x_n) \longrightarrow P(\xi \leq x) = F_\xi(x)$$

이다.

마지막으로 ξ 는 유한한 실수값을 갖는 함수이므로, 각각의 ω 에 대해 $\xi(\omega)$ 는 충분히 큰 양의 정수보다 작고, 충분히 작은 음의 정수보다 크다. 따라서

$$\{\xi \leq -n\} \searrow \emptyset, \quad \{\xi \leq n\} \nearrow \Omega.$$

확률의 연속성에 의해 $F_\xi(-n) \rightarrow 0$, $F_\xi(n) \rightarrow 1$ 이다. F_ξ 의 monotonicity를 함께 쓰면 정수열뿐 아니라 실수 $x \rightarrow \pm\infty$ 에 대해서도 원하는 극한을 얻는다. $\square$

여기서 얻은 것은 오른쪽 연속성이다. 모든 distribution function이 양쪽에서 연속이라는 결론은 아니다. 잠시 뒤 discrete distribution에서는 함수가 뛰는 모습을 만나게 된다. 오늘 정의가 많으므로, random variable에서 distribution으로, distribution에서 distribution function으로 넘어오는 관계를 한 번 정리하고 다음 정의를 보자.

density로 적분하는 distribution과 point probability를 더하는 distribution

같은 distribution을 law라고 부르기도 한다. 따라서 두 표현은 여기서 같은 대상을 가리킨다. 이제 계산에서 자주 만나는 두 경우를 보자. 하나는 density를 적분하는 경우이고, 다른 하나는 discrete distribution에서 각 값의 확률을 더하는 경우이다.

Definition 1.7: absolutely continuous distribution과 discrete distribution. 음이 아닌 Borel function $f_\xi : \mathbb{R} \rightarrow [0, \infty)$ 가 존재하여 모든 Borel set B 에 대해

$$P_\xi(B) = P(\xi \in B) = \int_B f_\xi(x) dx$$

를 만족하면 ξ 의 distribution이 **absolutely continuous**하다고 한다. f_ξ 를 **probability density function**이라고 한다. 여기서 dx 는 실수축의 Lebesgue measure에 대한 적분을 뜻한다.

서로 다른 값들의 집합 $\{x_i : i \in \mathcal{I}\}$ 가 유한하거나 countably infinite이고, 모든 Borel set B 에 대해

$$P(\xi \in B) = \sum_{i: x_i \in B} P(\xi = x_i)$$

이면 ξ 의 distribution을 **discrete distribution**이라고 한다.

density가 있으면 $B = \mathbb{R}$ 를 대입하여

$$\int_{\mathbb{R}} f_\xi(x) dx = 1$$

을 얻는다. discrete distribution에서는 마찬가지로

$$\sum_{i \in \mathcal{I}} P(\xi = x_i) = 1$$

이므로 이 값들이 전체 확률을 담고 있다. discrete라고 해서 가능한 값이 유한 개일 필요는 없다. $x_1, x_2, \dots$ 처럼 나열할 수 있는 무한한 경우도 허용한다.

두 모형은 확률을 계산하는 방식이 다르다. absolutely continuous인 경우에는 density를 적분하고, discrete인 경우에는 해당하는 점들의 확률을 더한다. 이들은 대표적인 두 경우이며, 여기서 모든 distribution이 반드시 둘 중 하나라고 가정하는 것은 아니다.

특히 density와 distribution function을 구별하자. density가 있을 때는

$$F_\xi(x) = \int_{-\infty}^x f_\xi(t) dt.$$

작은 f_ξ 를 왼쪽부터 x 까지 적분한 것이 큰 F_ξ 이다. density의 한 점에서의 높이 $f_\xi(x)$ 를 그 점이 나올 확률 $P(\xi = x)$ 로 읽어서는 안 된다. density로 표현되는 distribution에서는 한 점 위의 적분이 0이므로 point probability는 0이다.

density의 연속성이라는 추가 조건과 distribution function의 점프

Exercise 1.5 and 1.6. density f_ξ 가 연속이면 모든 $x \in \mathbb{R}$ 에서

$$F'_\xi(x) = f_\xi(x)$$

이다. discrete distribution의 경우에는 각 x_i 에서 distribution function의 점프 크기가

$$F_\xi(x_i) - F_\xi(x_i-) = P(\xi = x_i)$$

이다. 여기서 $F_\xi(x_i-) = \lim_{t \uparrow x_i} F_\xi(t)$ 는 왼쪽 극한이다.

첫 문장에 붙은 추가 조건을 꼭 보자. absolutely continuous distribution의 정의는 density가 Borel measurable이고 음이 아니며 확률을 적분으로 표현한다는 조건이지, density가 연속이라는 조건이 아니다. density가 연속일 때는 해석학에서 배운 적분과 미분의 관계를 이용하여 위 등식을 모든 점에서 말할 수 있다. 그 추가 조건을 빼고 모든 점에서의 미분 등식을 그대로 주장할 수는 없다.

discrete distribution에서는 x_i 직전까지 누적한 확률에 $\xi = x_i$ 인 사건의 확률이 더해진다. 그만큼 distribution function이 뛰는 것이다. 질량 $P(\xi = x_i)$ 가 양수인 곳에서는 실제로 점프가 생긴다. distribution function의 값 $F_\xi(x_i)$ 에는 바로 그 점의 확률까지 포함되어 있으므로, 이러한 점프는 앞에서 증명한 오른쪽 연속성과 모순되지 않는다.

두 성질의 증명은 여기서 길게 전개하지는 않는다. 지금 기억할 것은, density가 연속인 경우 distribution function을 미분하면 density를 얻고, discrete distribution에서는 distribution function의 점프가 point probability를 나타낸다는 관계이다. 이후의 정의로 넘어가기 전에 오늘 등장한 대상들의 역할을 충분히 익혀 두자.

probability space를 정보의 관점에서 다시 보기

지난 시간의 probability space $(\Omega, \mathcal{F}, P)$ 부터 다시 보자. 세 기호가 서로 다른 일을 한다. Ω 는 가능한 결과들을 모으고, sigma-field $\mathcal{F}$ 는 그 결과에 관해 물을 수 있는 사건들을 모은다. P 는 그렇게 고른 각 사건에 0과 1 사이의 확률을 붙인다.

sigma-field를 정보로 해석하면 그 정의도 자연스럽게 보인다. 사건 A 가 일어났는지 알면 A^c 가 일어났는지도 알 수 있다. 사건열 각각의 발생 여부를 알면 그중 적어도 하나가 일어났는지도 판단할 수 있다. 그래서 여집합과 countable union에 대해 닫혀 있도록 요구한다. $\mathcal{F}$ 는 우리가 결과에 관해 어떤 질문에 답할 수 있는지를 나타낸다.

density와 점프: 지난 distribution function 계산의 마무리

absolutely continuous distribution에서는 음이 아닌 Borel measurable 함수인 density f_ξ 가 있어서

$$P(\xi \in B) = \int_B f_\xi(x) dx, \quad F_\xi(x) = \int_{-\infty}^x f_\xi(t) dt$$

로 계산한다. $B = \mathbb{R}$ 를 대입하면 density의 적분은 1이므로 f_ξ 는 integrable하다. 그러나 integrable하다는 말과 연속이라는 말은 다르다. Exercise 1.5의 모든 점에서의 등식 $F'_\xi = f_\xi$ 에는 density의 연속성이라는 추가 조건이 있었다.

이제 Exercise 1.6의 discrete distribution을 보자. 서로 다른 값 x_i 들이 전체 확률을 담고 있을 때,

$$P(\xi \in B) = \sum_{i: x_i \in B} P(\xi = x_i)$$

이다. 값의 개수는 유한할 수도, countably infinite일 수도 있다. 이 distribution에서 $P(\xi = x_i) > 0$ 인 한 점은 probability mass를 담은 atom이라고 생각할 수 있다.

Exercise 1.6의 증명 $s < t$ 를 고정하면 $\{\xi \leq t\}$ 는 서로소인 두 사건 $\{\xi \leq s\}$ 와 $\{s < \xi \leq t\}$ 로 나뉜다. 따라서

$$F_\xi(t) - F_\xi(s) = P(s < \xi \leq t) = \sum_{i: s < x_i \leq t} P(\xi = x_i).$$

오른쪽 끝 t 는 포함되고 왼쪽 끝 s 는 제외된다. 구간 $(s, t]$ 안에 양의 질량이 없다면 이 차이는 0이다.

이제 $s_m \uparrow x_i$ 이고 $s_m < x_i$ 인 수열을 잡는다. 그러면 $\{\xi \leq s_m\} \uparrow \{\xi < x_i\}$ 이므로 확률의 연속성에 의해

$$F_\xi(x_i-) = P(\xi < x_i).$$

결국

$$F_\xi(x_i) - F_\xi(x_i-) = P(\xi \leq x_i) - P(\xi < x_i) = P(\xi = x_i)$$

이다. □

즉, x_i 직전까지 누적한 확률에 그 점의 질량이 추가되는 만큼 함수가 쏠린다. density를 적분하는 경우와 point mass를 더하는 경우의 차이를 이 두 계산에서 볼 수 있다. discrete distribution이라고 해서 반드시 서로 떨어진 유한 개의 점만 생각할 필요는 없다. 방금 계산은 유한하거나 countable 한 값의 모임에도 적용된다.

여러 관측량을 함께 다루는 joint distribution

지금까지는 random variable 하나의 distribution을 보았다. 실제로는 여러 수치를 동시에 관측할 수도 있다. 이때는 한 실수 대신 실수의 순서쌍이나 순서 있는 묶음이 관측값이 된다.

Definition (joint distribution). 같은 probability space 위의 random variable $\xi_1, \dots, \xi_n$ 의 joint distribution은

$$P_{\xi_1, \dots, \xi_n}(B) = P((\xi_1, \dots, \xi_n) \in B), \quad B \in \mathcal{B}(\mathbb{R}^n)$$

로 정의되는 $\mathbb{R}^n$ 위의 probability measure이다.

참자가 길어졌지만 정의의 방식은 같다. $\mathbb{R}^n$ 의 Borel set을 잡고, 관측한 묶음이 그 안에 들어가는 원래 결과들의 확률을 계산한다. 이 정의 자체에는 random variable들의 independence나 density의 존재를 가정하지 않는다.

expectation은 probability measure에 대한 적분이다

Definition (integrability와 expectation). random variable ξ 에 대하여

$$\xi \in L^1(\Omega, \mathcal{F}, P) \iff \int_{\Omega} |\xi| dP < \infty$$

로 쓴다. 이때

$$E(\xi) = \int_{\Omega} \xi dP$$

를 ξ 의 expectation이라고 한다.

ξ 에는 양수와 음수가 모두 나올 수 있다. 그 적분이 유한한 실수로 잘 정의되도록 절댓값의 적분이 유한하다는 조건을 둔다. 이 조건이면 양의 부분과 음의 부분의 적분이 모두 유한하므로 무한대끼리 빼는 문제가 생기지 않는다. 또

$$|E(\xi)| \leq E(|\xi|) < \infty$$

이다. random variable은 함수이지만, 그 expectation은 적분을 마친 하나의 실수이다.

Example: indicator function과 simple function. 사건 $A \in \mathcal{F}$ 의 indicator function은

$$\mathbb{1}_A(\omega) = \begin{cases} 1, & \omega \in A, \\ 0, & \omega \notin A \end{cases}$$

이다. 사건의 발생 여부를 1과 0으로 나타내는 random variable이다. $P(A) \leq 1$ 이므로 항상 integrable하고,

$$E(\mathbb{1}_A) = \int_{\Omega} \mathbb{1}_A dP = \int_A 1 dP = P(A)$$

이다. 일반적인 measure에서는 indicator function의 integrability에 집합의 유한 measure가 필요하지만, probability space에서는 자동으로 만족된다.

서로소인 사건 $A_1, \dots, A_n$ 과 실수 a_i 로 만든 simple function

$$\eta = \sum_{i=1}^n a_i \mathbb{1}_{A_i}$$

의 경우에는 적분의 linearity에 의해

$$E(\eta) = \sum_{i=1}^n a_i P(A_i).$$

각 구역에서 갖는 값에 그 구역의 확률을 곱해서 더한다. 유한 개의 값을 갖는 이러한 함수를 여기서 step function이라고도 부른다.

distribution만 알고 expectation을 계산하는 방법

실제 문제에서는 $\omega \mapsto \xi(\omega)$ 의 구체적인 모습은 모르고 ξ 의 distribution만 아는 경우가 많다. 그래도 $h(\xi)$ 의 expectation을 구할 수 있을까? 다음 공식이 그 일을 해 준다.

Exercise 1.7: LOTUS. Borel measurable function $h : \mathbb{R} \rightarrow \mathbb{R}$ 에 대해 $h(\xi) \in L^1$ 이면

$$E(h(\xi)) = \int_{\mathbb{R}} h(x) dP_{\xi}(x).$$

이를 law of the unconscious statistician, 줄여서 LOTUS라고 부른다. 특히

$$E(h(\xi)) = \begin{cases} \int_{\mathbb{R}} h(x) f_{\xi}(x) dx, & \text{density } f_{\xi} \text{가 있을 때,} \\ \sum_i h(x_i) P(\xi = x_i), & \text{discrete distribution일 때} \end{cases}$$

이다.

왼쪽은 Ω 위의 함수 $h \circ \xi$ 를 P 로 적분하고, 오른쪽은 실수축 위의 함수 h 를 distribution P_{ξ} 로 적분한다. 따라서 변환된 random variable $h(\xi)$ 의 distribution을 먼저 구하지 않아도 된다. 필요한 가정은 $h(\xi)$ 의 integrability이지, ξ 의 integrability를 별도로 요구하는 것이 아니다. density가 존재할 때 쓰는 첫 계산식에도 density의 연속성은 필요하지 않다.

증명의 방법은 indicator function에서 시작하여 일반 함수로 넓혀 가는 것이다. 먼저 $h = \mathbb{1}_B$ 이면

$$E(\mathbb{1}_B(\xi)) = P(\xi \in B) = P_{\xi}(B) = \int_{\mathbb{R}} \mathbb{1}_B dP_{\xi}$$

이므로 정의에서 바로 성립한다. indicator function의 유한 linear combination에도 적분의 linearity로 성립한다. 음이 아닌 Borel function은 아래에서 증가하는 음이 아닌 simple function들로 근사할 수 있고, 이때 적분도 극한으로 수렴한다는 monotone convergence theorem을 적용한다. 마지막으로 일반적인 h 는 양의 부분과 음의 부분으로 나눈다. $h(\xi)$ 의 absolute integrability 덕분에 양쪽 적분이 유한하여 뺄 수 있다. 근사를 만드는 전체 과정은 여기서 전개하지 않지만, 어느 단계에서 어떤 극한을 쓰는지는 기억해 두자.

variance를 정의하기 전에 확인할 것

평균으로부터 얼마나 떨어져 있는지를 제공하여 평균내면 variance가 된다. 하지만 ξ 를 적분할 수 있다고 해서 ξ^2 도 적분할 수 있는 것은 아니다.

Definition (L^2 와 variance).

$$\xi \in L^2(\Omega, \mathcal{F}, P) \iff E(\xi^2) < \infty.$$

이때 variance는

$$\text{var}(\xi) = E((\xi - E(\xi))^2) = E(\xi^2) - (E(\xi))^2$$

로 정의한다.

$m = E(\xi)$ 가 유한하면 두 번째 등식은

$$E(\xi^2 - 2m\xi + m^2) = E(\xi^2) - 2mE(\xi) + m^2 = E(\xi^2) - m^2$$

라는 전개이다. 여기서 m 은 random variable이 아니라 상수이고, 상수의 expectation은 그 상수이다.

여기서 한 가지를 먼저 확인해야 한다. L^2 라는 가정만으로 $m = E(\xi)$ 가 유한하다고 말할 수 있을까? probability space에서는 $L^2 \subset L^1$ 이므로 가능하다. 다음 부등식으로 이 포함관계를 확인하면, 방금 쓴 variance의 모든 항이 잘 정의된다는 점도 함께 해결된다.

Cauchy-Schwarz: 곱의 적분과 두 번째 moment

Exercise 1.8: Cauchy-Schwarz. $\xi, \eta \in L^2$ 이면

$$|E(\xi\eta)|^2 \leq E(\xi^2)E(\eta^2).$$

특히 $E(|\xi|) \leq \sqrt{E(\xi^2)}$ 이므로 $L^2 \subset L^1$ 이다.

Proof. 먼저 왼쪽의 expectation이 정의되는지 확인해야 한다. 실수의 제곱이 음이 아니므로

$$2|\xi\eta| \leq \xi^2 + \eta^2.$$

양변을 적분하면 오른쪽이 유한하여 $\xi\eta \in L^1$ 이다. 이 계산은 곱의 integrability를 보일 뿐, 아직 원하는 Cauchy-Schwarz 부등식을 주지는 않는다.

더 정확한 부등식을 얻기 위해 실수 t 에 대한 함수

$$q(t) = E((\xi - t\eta)^2) = E(\xi^2) - 2tE(\xi\eta) + t^2E(\eta^2)$$

를 보자. 제곱의 적분이므로 모든 t 에서 $q(t) \geq 0$ 이다. $E(\eta^2) > 0$ 이면 이 이차식의 판별식이 양수일 수 없으므로

$$4(E(\xi\eta))^2 - 4E(\xi^2)E(\eta^2) \leq 0$$

이다. $E(\eta^2) = 0$ 이면 q 는 일차 이하의 식이다. 모든 실수 t 에서 음이 아니려면 일차항의 계수도 0이어야 하므로 같은 결론을 얻는다.

마지막으로 ξ 대신 $|\xi|$, η 대신 상수함수 1을 대입하면

$$(E(|\xi|))^2 \leq E(\xi^2)E(1) = E(\xi^2).$$

제곱근을 취하면 원하는 포함관계가 나온다. □

이 포함관계에서 전체 공간의 크기를 사용했다. 일반적인 유한 measure μ 라면 오른쪽에 $\sqrt{\mu(\Omega)}$ 라는 인자가 더 붙는다. 반면 실수 전체의 Lebesgue measure는 무한하므로 같은 논리로 $L^2(\mathbb{R}) \subset L^1(\mathbb{R})$ 라고 말할 수 없다. 전체 크기가 정확히 1인 것은 지금 부등식의 상수에 영향을 주며, 포함관계에는 전체 measure의 유한성이 핵심이다. 다른 L^p 사이의 관계도 관심이 있으면 따로 살펴볼 만하다.

tail probability를 적분하여 두 번째 moment 구하기

Exercise 1.9: tail integral formula. 음이 아닌 random variable η 에 대해

$$E(\eta^2) = 2 \int_0^\infty tP(\eta > t) dt.$$

양변이 무한대인 경우도 허용하는 음이 아닌 적분의 등식이다.

앞에서는 유한한 expectation을 위해 L^1 을 가정했다. 여기서는 음이 아닌 함수의 적분이므로 $+\infty$ 도 허용할 수 있다. 양의 무한대와 음의 무한대를 빼는 상황이 아니기 때문이다. 이 공식을 쓰기 전에 $E(\eta^2) < \infty$ 를 가정할 필요는 없다.

Proof. 먼저 결과 ω 를 하나 고정해 보자. $a = \eta(\omega)$ 는 이제 음이 아닌 실수이다. 따라서

$$\int_0^\infty 2t \mathbb{1}_{\{a > t\}} dt = \int_0^a 2t dt = a^2.$$

a 이전에는 indicator function이 1이고 이후에는 0이다. 경계 한 점은 적분에 영향을 주지 않는다. 즉, 각각의 ω 에서

$$\eta(\omega)^2 = \int_0^\infty 2t \mathbb{1}_{\{\eta(\omega) > t\}} dt$$

라는 점별 등식이 성립한다.

이제 expectation을 취하면 ω 와 t 에 대한 이중적분이 된다. 여기서 쓰는 **Tonelli's theorem**은 음이 아닌 measurable function의 반복적분 순서를 바꿀 수 있다는 정리이다. 현재 P 는 유한 measure이고 dt 는 $[0, \infty)$ 위의 Lebesgue measure이다. η 가 measurable이므로 $\{(\omega, t) : t < \eta(\omega)\}$ 도 measurable이며, 적분함수는 음이 아니다. 따라서

$$\begin{aligned} E(\eta^2) &= \int_\Omega \int_0^\infty 2t \mathbb{1}_{\{\eta > t\}} dt dP \\ &= \int_0^\infty 2t \left(\int_\Omega \mathbb{1}_{\{\eta > t\}} dP \right) dt \\ &= 2 \int_0^\infty t P(\eta > t) dt. \end{aligned}$$

마지막 줄에서는 indicator function의 expectation이 그 사건의 확률이라는 계산을 사용했다. $\square$

이것을 coarea formula의 확률적 형태로 볼 수 있다. η^2 를 직접 적분하는 대신, 각각의 높이 t 를 넘을 확률을 모아 같은 양을 계산한다. 교재의 긴 풀이 대신 적분 순서 교환을 사용하면 이처럼 짧아진다. 더 일반적으로 $p > 0$ 이면 같은 방법으로

$$E(\eta^p) = p \int_0^\infty t^{p-1} P(\eta > t) dt$$

를 얻는다. 지금은 제곱의 경우를 중심으로 기억하자. 이 공식은 뒤의 4장에서 최대값에 관한 L^2 부등식을 다룰 때 다시 사용하게 된다.

1.3 conditional probability와 independence

새 정보를 얻으면 확률을 어떻게 바꿀까?

Definition (conditional probability). 사건 $A, B \in \mathcal{F}$ 와 $P(B) > 0$ 에 대해

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

를 B 가 주어졌을 때 A 의 conditional probability라고 한다.

B 가 일어났다고 알게 되면 고려할 결과들은 B 안에 있다. 따라서 A 에서도 B 안에 있는 부분 $A \cap B$ 만 남기고, 남은 전체인 B 의 확률이 1이 되도록 $P(B)$ 로 나눈다. 교집합은 정보를 반영해 범위를 제한하고, 분모는 다시 정규화하는 역할을 한다.

분모 때문에 $P(B) > 0$ 이 필요하다. 또 조건의 방향을 바꾸면 다른 질문이 된다. 일반적으로

$$P(A | B) \neq P(B | A)$$

이며, 두 식을 모두 정의하려면 각각의 분모가 양수여야 한다. 두 식의 분자는 같아도 분모는 다르다.

sample space를 나누어 확률을 계산하기

Exercise 1.10: law of total probability. 서로소인 사건 $B_1, B_2, \dots$ 가 $\bigcup_n B_n = \Omega$ 를 만족하고 $P(B_n) > 0$ 이면

$$P(A) = \sum_{n \geq 1} P(A | B_n)P(B_n).$$

전체 결과를 서로 겹치지 않는 경우들로 나누었다. 각 경우 안에서의 확률을 구하고 그 경우 자체의 확률로 가중하여 더하는 것이다.

Proof. $A = \bigcup_n (A \cap B_n)$ 이고 이 합집합은 서로소이다. 그러므로 countable additivity와 conditional probability의 정의를 차례로 적용하면

$$P(A) = \sum_n P(A \cap B_n) = \sum_n P(A | B_n)P(B_n)$$

이다. □

모든 B_n 이 전체를 덮는다는 조건과 서로소라는 조건이 각각 어디에 쓰였는지 확인해 보자. 이 계산에는 사건들의 independence가 필요하지 않다.

조건의 방향을 뒤집는 Bayes' formula

Remark: Bayes' rule. 위 분할 조건 아래 $P(A) > 0$ 이면

$$P(B_j | A) = \frac{P(A | B_j)P(B_j)}{\sum_{n \geq 1} P(A | B_n)P(B_n)}.$$

앞에서는 B_n 을 조건으로 A 를 보았다. 이번에는 A 를 알게 된 뒤 어느 B_j 에 해당하는지를 묻는다. 증명은 정의로 돌아가면 짧다.

$$P(B_j | A) = \frac{P(A \cap B_j)}{P(A)}.$$

분자는 $P(A | B_j)P(B_j)$ 이고, 분모는 방금 얻은 law of total probability로 표현된다. 그래서 위 식을 얻는다. 짧은 대수 계산이지만, 어떤 정보를 조건으로 삼는지를 바꾸어 준다는 의미가 있다.

independence는 모든 부분모임에 대한 조건이다

이제 사건의 independence에서 시작해 random variable의 independence로, 나아가 sigma-field의 independence로 개념을 넓혀 가자.

Definition (사건들의 independence). 두 사건 A, B 가

$$P(A \cap B) = P(A)P(B)$$

를 만족하면 independent라고 한다. $A_1, \dots, A_n$ 이 independent라는 것은 모든 $1 \leq k \leq n$ 과 서로 다른 첨자 $i_1, \dots, i_k$ 에 대해

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = \prod_{j=1}^k P(A_{i_j})$$

가 성립한다는 뜻이다.

여기서는 전체 n 개를 한꺼번에 교차한 식 하나만 확인해서는 안 된다. 두 개씩 골라 확인하는 pairwise independence만으로도 부족하다. 임의의 부분모임을 골라도 곱의 등식이 성립해야 한다. 이처럼 모든 부분모임을 확인한다는 점에서 전체 모임의 independence가 더 강한 조건이다.

Exercise 1.11. $P(B) > 0$ 이면

$$A, B \text{가 independent} \iff P(A | B) = P(A).$$

실제로 $P(A \cap B)/P(B) = P(A)$ 의 양변에 $P(B)$ 를 곱하면 정의의 식이 나온다. 따라서 “ B 를 알게 되어도 A 의 확률이 바뀌지 않는다”는 해석이 정확해진다. 이것은 확률에 관한 설명이며, 별도의 인과관계를 단정하는 정의는 아니다.

random variable의 independence와 expectation의 곱

Definition (random variable들의 independence). 모든 Borel set $A, B \subset \mathbb{R}$ 에 대해

$$P(\eta \in A, \xi \in B) = P(\eta \in A)P(\xi \in B)$$

이면 random variable η, ξ 가 independent라고 한다. 유한한 모임에서는 모든 Borel set의 선택에 대해 대응하는 사건들이 independent이어야 하며, 임의의 모임에서는 모든 유한 부분모임이 independent이어야 한다.

선포는 두 조건을 동시에 만족한다는 뜻이다. 왼쪽은 $\{\eta \in A\} \cap \{\xi \in B\}$ 의 확률이다. 이렇게 random variable의 independence를 사건들의 independence로 정의한다.

Proposition 1.1. $\xi_1, \dots, \xi_n \in L^1$ 이 independent이고 $\xi_1 \cdots \xi_n \in L^1$ 이면

$$E(\xi_1 \cdots \xi_n) = \prod_{i=1}^n E(\xi_i).$$

특히 independent인 $\xi, \eta \in L^2$ 에 대해서는

$$E(\xi\eta) = E(\xi)E(\eta)$$

가 성립하며, 이들을 uncorrelated라고 한다.

independence가 있으면 곱의 expectation을 각 expectation의 곱으로 분리할 수 있다. expectation 기호만 보고 언제나 이렇게 분리해도 된다고 생각해서는 안 된다. 여기서는 필요한 integrability와 independence를 함께 확인한다. 특히 L^2 인 두 변수의 경우에는 앞의 부등식에서 각 변수와 곱의 integrability를 이미 확보했다.

증명의 기본 출발점도 indicator function이다. independent인 사건들 A_i 에 대해

$$E\left(\prod_i \mathbb{1}_{A_i}\right) = P\left(\bigcap_i A_i\right) = \prod_i P(A_i) = \prod_i E(\mathbb{1}_{A_i}).$$

각 변수의 Borel function으로 만든 simple function들에는 이 식과 linearity를 적용한다. 음이 아닌 변수는 증가하는 simple function으로 근사해 monotone convergence theorem을 쓰고, 부호가 있는 변수는 양의 부분과 음의 부분으로 나누어 전개한다. integrability는 마지막에 유한한 expectation들을 더하고 빼도록 해 준다. 상세한 근사 구성은 생략하지만, independence가 실제로 쓰이는 출발점은 위 사건 교집합의 확률을 곱으로 바꾸는 단계이다.

independence를 다시 확인하고 정보 전체로 넓히기

두 사건의 independence는 $P(A \cap B) = P(A)P(B)$ 라는 등식이었다. 두 random variable의 independence는 모든 Borel set C, D 에 대해

$$P(\xi \in C, \eta \in D) = P(\xi \in C)P(\eta \in D)$$

가 성립한다는 뜻이었다. 모임이 커지면 모든 유한 부분모임에 대해 대응하는 조건을 확인한다.

곱의 expectation을 분리하는 명제에서는 integrability도 함께 보아야 한다. 각 변수와 곱이 integrable하다는 조건 아래 independence가 있으면

$$E(\xi_1 \cdots \xi_n) = \prod_i E(\xi_i)$$

이다. 특히 두 L^2 변수 ξ, η 가 $E(\xi\eta) = E(\xi)E(\eta)$ 를 만족하면 두 변수가 uncorrelated라고 한다. independent이면 이 등식이 성립하지만, 등식 하나가 성립한다고 independence까지 얻는 것은 아니다. uncorrelated라는 조건은 expectation의 등식 하나를 확인한다. 반면 independence는 모든 Borel set을 선택해서 만든 사건들의 확률을 확인한다. 두 조건이 요구하는 정보의 양이 다르다.

오늘은 independence를 sigma-field로 넓힌 뒤, 새 정보를 얻었을 때 평균을 어떻게 바꾸는지 살펴보자.

sigma-field들의 independence

사건 하나와 사건 하나를 비교하는 대신 정보의 묶음 전체를 비교하고 싶을 때가 있다. sigma-field의 independence는 두 정보 묶음에서 사건을 어떻게 하나씩 꺼내도 independent라는 조건이다.

Definition (sigma-field의 independence). $\mathcal{G}, \mathcal{H} \subset \mathcal{F}$ 가 sigma-field라 하자. 모든 $A \in \mathcal{G}, B \in \mathcal{H}$ 에 대해

$$P(A \cap B) = P(A)P(B)$$

이면 $\mathcal{G}$ 와 $\mathcal{H}$ 가 independent라고 한다.

$\mathcal{G}_1, \dots, \mathcal{G}_n$ 이 independent라는 것은 $A_i \in \mathcal{G}_i$ 를 어떻게 선택해도 사건들의 모임 $A_1, \dots, A_n$ 이 independent라는 뜻이다. 무한 모임의 independence는 모든 유한 부분모임의 independence로 정의한다.

$\mathcal{G}, \mathcal{H}$ 는 $\mathcal{F}$ 의 원소인 사건들이 아니라, $\mathcal{F}$ 에 포함되는 작은 sigma-field들이다. 사건끼리의 independence를 이렇게 집합들의 모임 전체의 조건으로 확장했다.

Exercise 1.12. random variable ξ, η 가 independent일 필요충분조건은 $\sigma(\xi)$ 와 $\sigma(\eta)$ 가 independent인 것이다.

Proof. 생성 sigma-field의 정의에 따라 모든 $A \in \sigma(\xi), B \in \sigma(\eta)$ 는 각각

$$A = \{\xi \in C\}, \quad B = \{\eta \in D\}$$

로 쓸 수 있다. 여기서 C, D 는 Borel set이며 같은 필요가 없다. 따라서 두 sigma-field의 independence에서 확인할 등식은

$$P(\xi \in C, \eta \in D) = P(\xi \in C)P(\eta \in D)$$

와 정확히 같다. 이것이 모든 C, D 에 대해 성립한다는 것이 두 random variable의 independence이므로 양방향으로 모두 얻는다. $\square$

random variable과 이미 주어진 정보의 independence

Definition (random variable과 sigma-field의 independence). random variable ξ 가 sigma-field $\mathcal{G}$ 와 independent라는 것은 $\sigma(\xi)$ 와 $\mathcal{G}$ 가 independent라는 뜻이다. random variable과 sigma-field가 함께 주어진 경우에도 같은 원리를 쓴다. 각 random variable을 그 변수가 생성하는 sigma-field로 바꾼 뒤, 이렇게 얻은 sigma-field들이 independent인지 확인한다.

정의를 새로 외우기보다, random variable에서 그 변수를 관측해 얻는 정보 $\sigma(\xi)$ 를 만든 뒤 비교한다고 생각해 보자. 그러면 서로 종류가 달라 보이던 대상들을 모두 sigma-field의 수준에서 다룰 수 있다. 여기까지가 이후 논의에 필요한 1장의 기본 언어이다.

2. conditional expectation

2.1 사건을 조건으로 하는 경우

새 정보가 들어오면 예측도 바뀐다. 앞으로 stochastic process를 다룰 때에는 시간이 지나면서 관측 정보가 쌓이고, 그 정보에 따라 평균적인 예측을 갱신하게 된다. conditional expectation은 바로 이런 일을 표현하는 언어이다.

정의를 한 번에 가장 일반적인 형태로 쓰기보다, 계산할 수 있는 경우에서 출발하자. 먼저 사건을 조건으로 평균을 구하고, 그다음 discrete random variable, 일반 random variable, 마지막으로 sigma-field 자체를 조건으로 주는 경우로 넓혀 간다.

Definition (사건에 대한 conditional expectation). $\xi \in L^1$ 이고 $B \in \mathcal{F}, P(B) > 0$ 일 때

$$E(\xi | B) = \frac{1}{P(B)} \int_B \xi dP$$

를 사건 B 가 주어졌을 때 ξ 의 conditional expectation이라고 한다.

B 가 일어났다고 알았으므로 전체 Ω 가 아니라 B 에서 평균을 낸다. 다만 원래 확률로 적분한 값을 $P(B)$ 로 나누어, 현재 고려하는 사건 안에서의 평균으로 정규화한다. $\int_B |\xi| dP \leq E(|\xi|) < \infty$ 이고 분모가 양수이므로 유한한 값이다.

$P(B) = 0$ 을 제외하는 이유는 이 비율을 정의할 수 없기 때문이다. 확률이 0인 사건은 아예 일어날 수 없다는 뜻으로 해석해서는 안 된다.

또 결과의 종류를 확인하자. 적분한 뒤 확률로 나누었으므로 $E(\xi | B)$ 는 실수이다. 잠시 뒤 random variable을 조건으로 하면 결과도 random variable이 된다. 같은 expectation 기호를 쓰더라도 무엇이 조건으로 들어가는지 보아야 한다.

세 동전의 합을 알고 싶은 경우

Example 2.1. 10p, 20p, 50p의 공정한 동전 세 개를 서로 independent하게 던진다. 앞면인 동전들의 금액 합을 ξ 라 하고, 정확히 두 동전이 앞면인 사건을 B 라 하자. 결과의 순서는 10p, 20p, 50p이다.

$$B = \{HHT, HTH, THH\}.$$

공정성과 independence 때문에 여덟 결과의 확률은 각각 $1/8$ 이다. 따라서 $P(B) = 3/8$ 이고,

ω	HHT	HTH	THH
$\xi(\omega)$	30	60	70

이다. 예를 들어 HTH 에서는 $10 + 0 + 50 = 60$ 이다. 그러므로

$$E(\xi | B) = \frac{30/8 + 60/8 + 70/8}{3/8} = \frac{160}{3}.$$

계산에서 $3/8$ 을 곱하는 것이 아니라 나눈다는 점에 주의하자. 원래 확률로 계산한 합을 B 안에서의 평균으로 바꾸는 것이다. 조건을 알게 된 뒤에는 세 결과의 conditional probability가 각각 $1/3$ 이므로 $(30 + 60 + 70)/3$ 으로 보아도 같다.

Exercise 2.1.

$$E(\xi | \Omega) = E(\xi).$$

전체 sample space에 속했다는 것은 새로운 정보를 주지 않는다. 실제로

$$E(\xi | \Omega) = \frac{1}{P(\Omega)} \int_{\Omega} \xi dP = \int_{\Omega} \xi dP = E(\xi)$$

이다.

Exercise 2.2. $A, B \in \mathcal{F}$, $P(B) > 0$ 이면

$$E(\mathbb{1}_A | B) = P(A | B).$$

indicator function을 B 에서 적분하면 $A \cap B$ 의 확률이므로

$$E(\mathbb{1}_A | B) = \frac{\int_B \mathbb{1}_A dP}{P(B)} = \frac{P(A \cap B)}{P(B)}.$$

따라서 conditional probability는 indicator function의 conditional expectation이라는 특수한 경우이다. 새로운 정의가 이전 정의를 포함한다는 점을 확인한 셈이다.

2.2 discrete random variable을 조건으로 하는 경우

여러 사건별 평균을 하나의 함수로 모으기

이번에는 사건 B 하나 대신 다른 random variable η 를 관측한다고 하자. η 가 어떤 값을 나타내는 지에 따라 알게 되는 사건이 달라진다. 한 사건의 평균을 미리 고정하는 대신, 관측값마다 사용할 평균을 정해 두어야 한다. 그래서 $E(\xi | \eta)$ 는 하나의 숫자가 아니라 관측에 따라 값이 달라지는 random variable로 정의한다.

Definition (discrete random variable에 대한 conditional expectation). $\xi \in L^1$ 이고 η 가 discrete distribution을 갖는다고 하자. 양의 확률을 갖는 서로 다른 값들의 집합은 유한하거나 countably infinite이다. 이 값들을 y_n 으로 나열하고

$$A_n = \{\eta = y_n\}, \quad c_n = E(\xi \mid A_n) = \frac{\int_{A_n} \xi dP}{P(A_n)}$$

로 둔다. $\eta(\omega) = y_n$ 일 때

$$E(\xi \mid \eta)(\omega) = c_n$$

으로 정의한다. 동등하게

$$E(\xi \mid \eta) = \sum_n c_n \mathbb{1}_{A_n}.$$

양의 확률을 갖는 값들 밖의 사건 $N = \{\eta \notin \{y_n : n \geq 1\}\}$ 은 확률이 0이며, 이 식은 그 위의 값을 0으로 정한 형태이다. 가능한 값이 유한하면 합도 그 유한한 범위에서 취한다.

먼저 ω 를 하나 정하고, $\eta(\omega)$ 를 계산하고, 그 관측값의 사건 A_n 에서 평균을 구하는 순서이다. $\eta(\omega) = y_n$ 이면 ω 를 대입한 합에서 n 번째 indicator function만 1이고 나머지는 0이다. 따라서 합의 표현과 사건별 정의가 같다.

여러 결과 ω 가 같은 관측값을 낼 수 있다. 그 결과들은 모두 같은 사건 A_n 에 들어가므로 conditional expectation도 같은 값 c_n 을 받는다. 관측으로 구별할 수 없는 결과들에 대해 다른 값을 주지 않는 것이다.

$E(\xi \mid \{\eta = y_n\})$ 는 특정 사건에서 계산한 실수이고, $E(\xi \mid \eta)$ 는 그런 실수들을 관측에 맞추어 배치한 함수이다. 확률 0인 사건으로 나누어 계산하는 일은 하지 않았다.

두 동전의 금액만 관측하면 무엇이 남을까?

Example 2.2. 앞의 independent이고 공정한 세 동전으로 돌아가자. ξ 는 앞면인 동전들의 전체 금액이고, η 는 10p와 20p 동전에서 온 금액만 센다. 따라서

$$\eta \in \{0, 10, 20, 30\}.$$

두 작은 동전이 모두 뒷면이면 0, 10p만 앞면이면 10, 20p만 앞면이면 20, 둘 다 앞면이면 30이다.

먼저 $\eta = 0$ 을 관측했다고 하자. 첫 두 동전은 뒷면이고, 마지막 동전만 모른다. 가능한 결과는 TTH 와 TTT 이며, 각각 $\xi = 50$ 과 $\xi = 0$ 이다. 두 결과의 원래 확률은 각각 $1/8$ 이므로

$$E(\xi \mid \{\eta = 0\}) = \frac{50/8 + 0/8}{1/4} = 25.$$

같은 계산을 나머지 관측값에 적용하면

η	0	10	20	30
$E(\xi \mid \eta)$	25	35	45	55

를 얻는다. 따라서 이 예에서

$$E(\xi \mid \eta) = \eta + 25.$$

식의 의미를 먼저 예상할 수도 있다. η 를 알면 두 작은 동전에서 온 금액은 이미 확정된다. 아직 모르는 부분은 50p 동전의 기여뿐이고, 그 평균은 $50 \cdot \frac{1}{2} = 25$ 이다. independence 때문에 앞의 두 동전 정보를 얻어도 마지막 동전의 앞면 확률은 여전히 $1/2$ 이다. 그래서 관측한 금액에 25를 더한다. 표에서 보듯 conditional expectation의 값은 관측에 따라 달라진다.

연속적인 함수를 거친 관측으로 평균내기

discrete인 것은 조건으로 주는 η 이다. 평균내려는 ξ 까지 discrete일 필요는 없다. 이를 단위구간의 예로 보자.

Example 2.3.

$$\Omega = [0, 1], \quad \mathcal{F} = \mathcal{B}([0, 1]), \quad P(A) = \text{Leb}(A)$$

로 두고 $\xi(x) = 2x^2$ 라 하자. 관측량은

$$\eta(x) = \begin{cases} 0, & 0 \leq x \leq \frac{1}{3}, \\ 1, & \frac{1}{3} < x \leq \frac{2}{3}, \\ 2, & \frac{2}{3} < x \leq 1. \end{cases}$$

이다. ξ 의 그래프는 이차함수이지만 η 의 그래프는 각 삼등분 구간에서 일정한 세 층으로 이루어진다.

첫 구간의 점 x 에서는 $\eta(x) = 0$ 이므로

$$E(\xi | \eta)(x) = \frac{1}{1/3} \int_0^{1/3} 2t^2 dt = 3 \cdot \frac{2}{3} \left(\frac{1}{3}\right)^3 = \frac{2}{27}.$$

적분변수 t 와 결과를 평가하는 점 x 를 구별해 두자. x 가 첫 구간 어디에 있든 적분하는 범위는 첫 구간 전체이다.

나머지도 각 구간에서 적분하고 길이 $1/3$ 으로 나눈다.

$$3 \int_{1/3}^{2/3} 2t^2 dt = 2 \left[\left(\frac{2}{3}\right)^3 - \left(\frac{1}{3}\right)^3 \right] = \frac{14}{27},$$

$$3 \int_{2/3}^1 2t^2 dt = 2 \left[1 - \left(\frac{2}{3}\right)^3 \right] = \frac{38}{27}.$$

따라서

$$E(\xi | \eta)(x) = \begin{cases} \frac{2}{27}, & 0 \leq x \leq \frac{1}{3}, \\ \frac{14}{27}, & \frac{1}{3} < x \leq \frac{2}{3}, \\ \frac{38}{27}, & \frac{2}{3} < x \leq 1. \end{cases}$$

관측한 것은 x 의 정확한 위치가 아니라 어느 삼등분 구간에 속하는지이다. 따라서 같은 구간 안에서는 다른 점들을 구별할 수 없고, 그 구간의 평균 하나를 준다. 동전 예에서는 합으로 계산했고 지금은 적분으로 계산했지만, 관측이 정하는 사건마다 평균을 낸다는 원리는 같다.

상수 관측과 두 가지 값의 관측

Exercise 2.3. $\eta \equiv C$ 가 상수이면 $E(\xi | \eta) = E(\xi)$ 이다.

유일한 비어 있지 않은 관측 사건은 $\{\eta = C\} = \Omega$ 이다. 그러므로

$$E(\xi | \eta) = E(\xi | \Omega) \mathbb{1}_\Omega = E(\xi).$$

왼쪽은 random variable이고 오른쪽은 그 상숫값이다. 즉, 모든 결과에서 전체 평균을 반환하는 상수함수이다. 항상 같은 관측값이 나온다면 결과를 구별하는 정보가 없다는 해석과 일치한다.

Exercise 2.4. $A, B \in \mathcal{F}$ 이고 $0 < P(B) < 1$ 이면

$$E(\mathbb{1}_A | \mathbb{1}_B) = P(A | B) \mathbb{1}_B + P(A | B^c) \mathbb{1}_{B^c}.$$

상수 관측에서는 사건이 하나였는데, 여기서는 어떤 두 사건으로 나눌까? $\mathbb{1}_B = 1$ 이면 B 이고 $\mathbb{1}_B = 0$ 이면 B^c 이다. 두 사건의 확률이 모두 양수이므로 각각에서 평균을 계산할 수 있다. 그리고 Exercise 2.2에 따라 그 평균들은 $P(A | B)$ 와 $P(A | B^c)$ 이다. 이것을 두 사건의 indicator function에 붙이면 위 식이 된다.

계산식에서 공통 성질을 찾아내기

지금까지는 각 관측값에 맞춰 직접 함숫값을 정했다. 그런데 이렇게 만든 함수가 integrable한지, 그리고 원래 함수와 어떤 관계를 유지하는지는 아직 확인해야 한다. 다음 성질들이 일반적인 conditional expectation으로 넘어가는 출발점이 된다.

Proposition 2.1. $\xi \in L^1$ 이고 η 가 discrete distribution을 가지면 $Z = E(\xi | \eta)$ 는 integrable하며 다음을 만족한다.

1. Z 는 $\sigma(\eta)$ -measurable이다.
2. 모든 $A \in \sigma(\eta)$ 에 대해

$$\int_A Z dP = \int_A \xi dP.$$

첫째 조건은 단순한 $\mathcal{F}$ -measurability보다 강하다. 전체 정보가 아니라 η 를 관측해서 얻는 정보만으로 Z 를 알 수 있다는 뜻이다. 둘째 조건은 그 정보로 식별할 수 있는 어떤 사건에서든 적분이 보존된다는 뜻이다. 함수 자체는 달라졌어도 관측 가능한 사건마다 합산한 값은 같게 유지된다.

measurability, integrability, 적분 보존을 각각 확인하기

Proof. 정의에 사용한 기호를 다시 쓰자.

$$A_n = \{\eta = y_n\}, \quad c_n = \frac{\int_{A_n} \xi dP}{P(A_n)}, \quad Z = \sum_n c_n \mathbb{1}_{A_n}.$$

먼저 A_n 은 η 에 의한 Borel set $\{y_n\}$ 의 역상이므로 $\sigma(\eta)$ 에 속한다. 따라서 각 indicator function도 $\sigma(\eta)$ -measurable이다. 유한 합은 measurable이고, 항들을 자연수로 나열하여 무한히 더하는 경우 부분합이 점별로 Z 에 수렴하므로 그 극한도 measurable이다. 한 결과에서는 많아야 한 항만 남기 때문에 이 극한도 명확하다. N 위에서는 모든 항이 0이다.

다음은 integrability이다. 서로소인 A_n 들 위에서는

$$|Z| = \sum_n |c_n| \mathbb{1}_{A_n}.$$

음이 아닌 항들의 합이므로 monotone convergence로 적분과 합을 바꿀 수 있고,

$$\begin{aligned} E(|Z|) &= \sum_n |c_n| P(A_n) \\ &= \sum_n \left| \int_{A_n} \xi dP \right| \\ &\leq \sum_n \int_{A_n} |\xi| dP = E(|\xi|) < \infty. \end{aligned}$$

분모 $P(A_n)$ 가 약분된 뒤, 적분의 절댓값을 절댓값의 적분으로 추정했다. A_n 들이 덮지 못하는 N 은 확률이 0이어서 마지막 적분에 영향을 주지 않는다. ξ 의 integrability가 Z 의 integrability를 보장하는 지점이 여기이다.

마지막으로 임의의 $A \in \sigma(\eta)$ 를 잡는다. 어떤 Borel set D 에 대해 $A = \{\eta \in D\}$ 이므로, N 밖에서는

$$A \setminus N = \bigcup_{n: y_n \in D} A_n.$$

가능한 관측값 중 어느 것들을 허용하는지 고르면 그 관측값의 사건들을 합치는 것이다. $\mathcal{J} = \{n : y_n \in D\}$ 라 쓰면

$$\begin{aligned}\int_A Z dP &= \sum_{n \in \mathcal{J}} c_n P(A_n) \\ &= \sum_{n \in \mathcal{J}} \int_{A_n} \xi dP = \int_A \xi dP.\end{aligned}$$

이미 Z 와 ξ 가 absolutely integrable하므로 서로소 countable union에 대한 적분을 이처럼 나누어도 된다. $A \cap N$ 의 적분은 양쪽 모두 0이다. 가능한 값들이 모든 결과를 덮는 경우에는 N 이 빈집합이어서 단순히 $A = \bigcup_{n \in \mathcal{J}} A_n$ 이다. $\square$

이제 사건 하나를 조건으로 하는 평균에서 출발해 discrete 관측 전체에 대한 함수까지 만들었다. 다음에는 η 가 discrete이 아닐 때로 넘어간다. 그때도 관측 정보에 대한 measurability와 각 관측 가능한 사건에서의 적분 보존이라는 두 성질을 계속 보게 된다.

2.3 일반 random variable을 조건으로 하는 경우

지난 시간에는 두 종류의 conditional expectation을 정의했다. 사건 B 를 조건으로 하면

$$E(\xi | B) = \frac{1}{P(B)} \int_B \xi dP$$

라는 실수가 나온다. 여기서 $\xi \in L^1$ 이고 $P(B) > 0$ 이어야 한다. 반면 discrete random variable η 를 조건으로 하면, 관측값에 따라 서로 다른 사건별 평균을 골라 주는 함수가 나왔다.

$$E(\xi | \eta)(\omega) = E(\xi | \{\eta = y_n\}) \quad \text{if } \eta(\omega) = y_n.$$

먼저 ω 에서 관측값을 읽고 그 값의 역상인 사건에서 평균을 계산하는 방식이었다.

그렇게 만든 함수 Z 에 대해 Proposition 2.1에서 확인한 성질을 기억해 보자. Z 는 integrable하고 $\sigma(\eta)$ -measurable이며, 모든 $A \in \sigma(\eta)$ 에 대해

$$\int_A Z dP = \int_A \xi dP$$

였다. $\mathcal{F}$ -measurable이라는 말만으로 끝나지 않고, 관측으로 얻는 더 작은 정보 $\sigma(\eta)$ 에 대한 measurability가 있다는 점이 중요하다.

직접 값을 주는 정의에서 성질로 정하는 정의로

이제 η 가 discrete이 아니라고 생각해 보자. 관측값 하나의 사건 $\{\eta = y\}$ 에 양의 확률이 있다는 보장이 없다. 그러므로 앞서처럼 그 사건의 확률로 나누어 함수값을 정하는 방법을 일반적으로 사용할 수 없다.

대신 방금 복습한 두 성질을 정의로 삼자.

Definition (일반 random variable에 대한 conditional expectation). $\xi \in L^1$ 이고 η 가 임의의 실수값 random variable이라 하자. integrable한 random variable Z 가 다음을 만족하면 ξ 의 η 에 대한 conditional expectation이라고 하고 $E(\xi | \eta)$ 로 쓴다.

1. Z 는 $\sigma(\eta)$ -measurable이다.
2. 모든 $A \in \sigma(\eta)$ 에 대해 $\int_A Z dP = \int_A \xi dP$ 이다.

첫 조건은 관측한 정보만으로 Z 의 값을 알 수 있어야 한다는 뜻이다. 둘째 조건은 그 정보로 구별할 수 있는 사건마다 Z 와 원래 함수의 적분이 같아야 한다는 뜻이다. discrete인 경우에는 이미 이 두 성질을 증명했다. 이제 그 성질들을 정의로 삼아 더 일반적인 관측까지 다루는 것이다.

이전에는 각 ω 에서 값을 명시했지만, 지금은 만족해야 할 성질로 함수를 정했다. 따라서 세 질문이 생긴다. 그런 함수가 존재할까? 하나로 정해질까? 실제 계산에서는 어떻게 찾을까?

존재는 measure theory의 존재정리에 의해 보장된다는 사실을 사용하자. 그 정리의 증명은 여기서 다루지 않는다. 지금 직접 보일 것은 유일성이며, 이후에는 두 조건을 이용해 구체적인 함수를 찾아보자. 입력인 ξ 와 η 가 명시되어 있어도 conditional expectation의 모양이 곧바로 보이는 것은 아니다.

conditional probability도 같은 방식으로 정의한다

Conditional Probability. 사건 $A \in \mathcal{F}$ 에 대하여

$$P(A | \eta) = E(\mathbb{1}_A | \eta)$$

로 정의한다.

indicator function은 probability space에서 항상 integrable하므로 방금 정의를 적용할 수 있다. 이때 $P(A | \eta)$ 도 Ω 위의 random variable이다. 특정 사건 B 를 주고 계산한 실수 $P(A | B)$ 와 종류를 구별해 두자. 여기서는 확률 0인 level set의 확률로 나누는 식을 정의에 사용하지 않는다.

모든 관측 가능한 사건에서 적분이 0이라면

Lemma 2.1. sigma-field $\mathcal{G} \subset \mathcal{F}$ 와 integrable하고 $\mathcal{G}$ -measurable인 random variable ξ 를 생각하자. 모든 $B \in \mathcal{G}$ 에 대해

$$\int_B \xi dP = 0$$

이면 $\xi = 0$ a.s., 즉 $P(\xi \neq 0) = 0$ 이다.

전체 공간에서 적분이 0이라는 조건 하나만으로 함수가 0이라고 결론낼 수는 없다. 양수와 음수가 상쇄될 수 있기 때문이다. 여기서는 $\mathcal{G}$ 의 모든 사건에서 확인하며, 함수도 바로 그 $\mathcal{G}$ 에 대해 measurable이라고 요구한다. 이 measurability가 있어야 함수의 양수 부분과 음수 부분을 구별해 시험할 수 있다.

Proof. 목표는 $\{\xi \neq 0\}$ 의 확률이 0임을 보이는 것이다. 먼저 $\epsilon > 0$ 을 고정하고

$$B_+ = \{\xi \geq \epsilon\}, \quad B_- = \{\xi \leq -\epsilon\}$$

로 두자. ξ 의 $\mathcal{G}$ -measurability 때문에 두 사건 모두 $\mathcal{G}$ 에 속한다. 따라서 가정의 적분 등식에 이 사건들을 넣을 수 있다.

B_+ 에서는 $\xi \geq \epsilon$ 이므로

$$0 = \int_{B_+} \xi dP \geq \epsilon P(B_+) \geq 0.$$

ϵ 이 양수이므로 $P(B_+) = 0$ 이다. 마찬가지로 B_- 에서는

$$0 = \int_{B_-} \xi dP \leq -\epsilon P(B_-) \leq 0$$

이어서 $P(B_-) = 0$ 이다.

이제 $\epsilon = 1/n$ 을 사용한다. 양수인 실수는 어떤 $1/n$ 보다 크거나 같고, 음수인 실수는 어떤 $-1/n$ 보다 작거나 같으므로

$$\{\xi \neq 0\} = \bigcup_{n \geq 1} \{\xi \geq 1/n\} \cup \bigcup_{n \geq 1} \{\xi \leq -1/n\}.$$

각 사건의 확률이 0이고 이 사건들을 자연수 n 으로 나열할 수 있으므로, countable subadditivity에 의해 $P(\xi \neq 0) = 0$ 이다. $\square$

양수인 부분만 보고 끝내지 않고 음수인 부분도 확인해야 한다. 또 집합들을 $\mathcal{G}$ 안에서 선택할 수 있었다는 것이 핵심이다. 단순히 더 큰 $\mathcal{F}$ 에 대해 measurable이라는 사실만으로는 이 증명의 시험 사건들을 사용할 수 없다.

conditional expectation의 유일성은 almost sure 유일성이다

Remark: 유일성과 a.s. 같은 입력. 같은 ξ, η 에 대해 conditional expectation의 정의를 만족하는 두 random variable은 almost surely 같다. 또한 $\xi = \xi'$ a.s.이면

$$E(\xi | \eta) = E(\xi' | \eta) \quad \text{a.s.}$$

이다.

Proof. 먼저 Z, Z' 가 같은 입력에 대한 정의를 만족한다고 하자. $Z - Z'$ 는 integrable하고 $\sigma(\eta)$ -measurable이다. 모든 $A \in \sigma(\eta)$ 에 대해

$$\int_A (Z - Z') dP = \int_A \xi dP - \int_A \xi dP = 0.$$

Lemma 2.1에 $\mathcal{G} = \sigma(\eta)$ 를 대입하면 $Z - Z' = 0$ a.s.를 얻는다.

다음으로 $\xi = \xi'$ a.s.이면 두 함수는 확률 0인 부분에서만 다르므로 모든 사건 A 에서 적분이 같다. 따라서 각각의 conditional expectation을 Z, Z' 라고 할 때 위 차이의 적분은 여전히 0이고, 같은 lemma를 적용할 수 있다. $\square$

유일하다는 말을 모든 점에서 값이 같다는 뜻으로 읽으면 안 된다. 정의를 만족하는 두 함수도 확률 0인 부분에서는 값이 다를 수 있다. 따라서 실제 계산으로 식 하나를 찾으면, conditional expectation을 나타내는 대표 함수 하나를 찾은 것이다. 존재는 앞서 사용한 정리가 보장한다. 방금 증명으로 얻은 것은 두 대표가 a.s. 같다는 의미의 유일성이다.

관측이 일정한 구간에서 후보의 값을 찾기

Exercise 2.4: 일부 구간만 구별하는 관측. 단위구간의 probability space

$$\Omega = [0, 1], \quad \mathcal{F} = \mathcal{B}([0, 1]), \quad P(A) = \text{Leb}(A)$$

에서

$$\xi(x) = 2x^2, \quad \eta(x) = \begin{cases} 2, & 0 \leq x < \frac{1}{2}, \\ x, & \frac{1}{2} \leq x \leq 1 \end{cases}$$

라 하자. $E(\xi | \eta)$ 를 구해 보자.

ξ 는 이차함수이고, η 는 앞 절반에서 상수 2, 뒤 절반에서 항등함수이다. η 가 모든 곳에서 discrete인 것은 아니므로 이전의 discrete인 경우의 공식만으로 계산하지 않는다.

첫 조건인 $\sigma(\eta)$ -measurability부터 이용하자. Doob-Dynkin lemma에 의해

$$E(\xi | \eta) = h(\eta)$$

인 Borel function h 가 존재한다. Borel function과 η 를 합성하면 $\sigma(\eta)$ -measurable이라는 쉬운 방향의 역이었다. 아직 h 는 모르지만, 찾아야 할 함수의 형태를 얻었다. 이제 둘째 조건인 적분 등식으로 h 의 값을 찾자.

사건 $L = \{\eta = 2\} = [0, 1/2)$ 를 대입하면

$$\int_L h(\eta) dP = \int_L \xi dP.$$

이 구간에서 $h(\eta) = h(2)$ 는 상수이므로 왼쪽은 $h(2)/2$ 이고, 오른쪽은

$$\int_0^{1/2} 2x^2 dx = \frac{2}{3} \left(\frac{1}{2} \right)^3 = \frac{1}{12}.$$

따라서 $h(2) = 1/6$ 이다. 한 사건을 사용하여 h 의 한 값을 알아냈다. 이제 다른 관측 가능한 사건들을 시험해 나머지 필요한 정보를 얻어 보자.

관측이 항등함수인 구간에서 값을 찾기

이번에는 임의의 Borel set $B \subset [1/2, 1]$ 를 잡는다. 앞 절반에서 η 의 값은 2이고 뒤 절반에서는 $\eta(x) = x$ 이므로

$$\{\eta \in B\} = B.$$

따라서 이 집합도 $\sigma(\eta)$ 의 사건이다. 둘째 조건은

$$\int_B h(x) dx = \int_B 2x^2 dx$$

가 된다. B 를 하나만 고정한 것이 아니라 이 구간의 모든 Borel set을 허용했으므로, 앞의 lemma와 같은 level set 논증으로

$$h(x) = 2x^2 \quad \text{Lebesgue measure에 대해 거의 모든 } x \in [1/2, 1]$$

을 얻는다. 이 구간에서는 $h(\eta(x)) = h(x)$ 이고 conditional expectation이 integrable하므로 차이의 적분을 다룰 수 있다.

여기서는 실수축의 Lebesgue measure를 기준으로 a.e.라고 말했다. probability space 위의 함수들에 대한 a.s.와 무엇을 기준으로 한 null set인지 구별해 두자. 이 예의 바탕공간에서는 probability measure가 Lebesgue measure의 제한이어서 두 관점이 연결된다.

h 가 실수 전체에서 결정된 것은 아니다. 그러나 관측값은 $\{2\} \cup [1/2, 1]$ 에만 있으므로 그 밖의 값은 합성 $h(\eta)$ 에 사용되지 않는다. $\eta = 2$ 에는 확률 $1/2$ 가 붙어 있어 $h(2)$ 가 고정되는 반면, 연속적인 구간에서의 값은 거의 모든 점에서만 정해졌다는 차이도 보인다.

후보를 정의한 뒤 두 조건을 다시 확인하기

지금까지 얻은 정보를 바탕으로 실제 Borel function 하나를 정의하자.

$$h(y) = \begin{cases} \frac{1}{6}, & y = 2, \\ 2y^2, & \frac{1}{2} \leq y \leq 1, \\ 0, & \text{그 밖의 경우.} \end{cases}$$

그러면

$$Z(x) = h(\eta(x)) = \begin{cases} \frac{1}{6}, & 0 \leq x < \frac{1}{2}, \\ 2x^2, & \frac{1}{2} \leq x \leq 1. \end{cases}$$

이다. 관측값이 될 수 없는 곳에서 h 를 0 대신 다른 값으로 정해도 합성은 바뀌지 않는다.

이렇게 값을 찾았다고 계산이 끝난 것은 아니다. 지금까지는 답이 되려면 어떤 형태여야 하는지를 구했다. 이제 그 후보가 실제로 정의의 두 조건과 integrability를 만족하는지 확인해야 한다.

후보의 검증 h 가 Borel function이므로 $Z = h(\eta)$ 는 $\sigma(\eta)$ -measurable이다. 또한 $|Z| \leq 2$ 이므로 probability space에서 integrable하다.

모든 $A \in \sigma(\eta)$ 는 어떤 Borel set D 의 역상이다. D 가 2를 포함하느냐에 따라, 그 역상은 B 또는 $L \cup B$ 꼴이다. 여기서 $L = [0, 1/2)$ 이고 $B = D \cap [1/2, 1]$ 이다. 즉, 앞 절반 전체를 넣거나 빼고, 뒤 절반에서는 임의의 Borel subset을 선택한다.

이미

$$\int_L Z dP = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12} = \int_L \xi dP$$

이고, 뒤 절반에서는 $Z = \xi$ 이므로 모든 그러한 B 에 대해 두 적분이 같다. L 과 B 가 서로소이므로 적분의 additivity를 쓰면 $L \cup B$ 에서도 같다. 따라서 모든 $A \in \sigma(\eta)$ 에 대한 둘째 조건이 성립한다. $\square$

그러므로 위의 Z 가 $E(\xi | \eta)$ 의 한 대표이다. 이 계산의 순서를 기억하자. measurability에서 $h(\eta)$ 라는 형태를 얻고, 적분 등식에서 필요한 h 의 값을 찾은 뒤, 함수를 실제로 정의하여 measurability · integrability · 모든 시험 사건에서의 등식을 확인했다.

함수의 모양으로 예상해 보는 연습

앞의 답을 관측의 관점에서 다시 보자. η 가 일정한 앞 절반에서는 서로 다른 x 를 전혀 구별하지 못한다. 그래서 conditional expectation도 그 구간에서 일정해야 한다. 반면 뒤 절반에서는 관측값이 곧 x 이므로 원래의 $\xi(x)$ 를 알 수 있고, 답도 원래 이차함수와 같아진다. 계산 전에도 이런 형태는 예상할 수 있었다.

Exercise 2.6. 같은 단위구간과 Lebesgue measure를 제한한 probability measure 위에서

$$\xi(x) = 2x^2, \quad \eta(x) = 1 - |2x - 1|$$

일 때 $E(\xi | \eta)$ 를 구해 보자.

이번 η 의 그래프는 1/2에서 꼭짓점을 갖는 삼각형 모양이다. $\eta(x) = \eta(1-x)$ 이므로 서로 대칭인 두 점이 같은 관측값을 준다. 따라서 $h(\eta)$ 형태로 잡은 conditional expectation도 이 대칭을 가져야 한다. 이 symmetry와 적분 조건을 함께 이용해 직접 계산해 보자. 이어서 다른 종류의 예를 하나 더 보자.

함수의 모양 대신 joint density만 주어진 경우

Exercise 2.7. 두 random variable ξ, η 의 joint density가

$$f_{\xi, \eta}(x, y) = \begin{cases} x + y, & (x, y) \in [0, 1]^2, \\ 0, & \text{그 밖의 경우} \end{cases}$$

일 때 $E(\xi | \eta)$ 를 구하자.

density는 음이 아니며 $\int_0^1 \int_0^1 (x + y) dx dy = 1$ 이다. 앞의 예와 달리 random variable 자체의 구체적인 함수식은 주어지지 않았다. 그래도 joint distribution을 알면 계산할 수 있다.

바탕공간으로 Borel sigma-field와 Lebesgue measure를 제한한 probability measure를 갖는 단위정사각형을 생각할 수도 있다. 하지만 그때에도 ξ, η 를 원래 공간의 좌표함수라고 가정한 것은 아니다. 여기서 density의 인수 x, y 는 두 random variable의 값을 나타낸다. 계산에 사용할 것은 바탕공간의 직접적인 좌표가 아니라 주어진 joint distribution이다.

이번에도 $E(\xi | \eta) = h(\eta)$ 로 쓰고, 임의의 Borel set $B \subset \mathbb{R}$ 에 대한 사건 $\{\eta \in B\}$ 를 시험한다.

$$\int_{\{\eta \in B\}} h(\eta) dP = \int_{\{\eta \in B\}} \xi dP.$$

두 적분을 joint density로 계산하여 h 를 찾으면 된다.

두 적분을 비교하여 함수값 결정하기

먼저 왼쪽은 joint distribution에 대한 적분으로 바꾸면

$$\begin{aligned} \int_{\{\eta \in B\}} h(\eta) dP &= \int_B \int_{\mathbb{R}} h(y) f_{\xi, \eta}(x, y) dx dy \\ &= \int_{B \cap [0, 1]} h(y) \left(\int_0^1 (x + y) dx \right) dy \\ &= \int_{B \cap [0, 1]} h(y) \left(\frac{1}{2} + y \right) dy. \end{aligned}$$

$h(y)$ 는 안쪽 적분의 변수 x 에 의존하지 않으므로 밖으로 꺼냈다. density가 정사각형 밖에서 0이라는 사실 때문에 적분 범위도 제한된다. B 가 실수 전체의 임의의 Borel set이라면 $B \cap [0, 1]$ 을 써야 한다.

오른쪽에서는 ξ 에 대응하는 x 가 한 번 더 곱해진다.

$$\begin{aligned}\int_{\{\eta \in B\}} \xi dP &= \int_B \int_{\mathbb{R}} x f_{\xi, \eta}(x, y) dx dy \\ &= \int_{B \cap [0, 1]} \left(\int_0^1 x(x+y) dx \right) dy \\ &= \int_{B \cap [0, 1]} \left(\frac{1}{3} + \frac{y}{2} \right) dy.\end{aligned}$$

여기서는 joint distribution에 대한 LOTUS와 반복적분을 사용했다. 후보를 유도할 때의 $h(\eta)$ 는 conditional expectation이어서 integrable하고, ξ 도 $0 \leq \xi \leq 1$ a.s.이므로 integrable하다. 따라서 absolutely integrable한 함수의 반복적분을 허용하는 Fubini's theorem을 적용할 수 있다.

모든 B 에 대해 두 적분이 같으므로, 차이의 양수 · 음수 level set을 시험하는 논증에 의해

$$h(y) \left(\frac{1}{2} + y \right) = \frac{1}{3} + \frac{y}{2} \quad \text{a.e. on } [0, 1].$$

이 구간에서는 분모가 양수이므로

$$h(y) = \frac{\frac{1}{3} + \frac{y}{2}}{\frac{1}{2} + y} = \frac{2 + 3y}{3(1 + 2y)} \quad \text{a.e. on } [0, 1]$$

을 얻는다. 분모 $\frac{1}{2} + y$ 는 joint density를 x 에 대해 적분한 η 의 marginal density이다. 이번에는 marginal density가 구간 전체에서 양수이므로 나누는 데 문제가 없다.

새 후보의 검증과 다음 단계

실수 전체에서 정의된 함수로 만들기 위해

$$h(y) = \begin{cases} \frac{2 + 3y}{3(1 + 2y)}, & 0 \leq y \leq 1, \\ 0, & \text{그 밖의 경우} \end{cases}$$

로 정하고 $Z = h(\eta)$ 를 택하자. h 는 Borel function이고 $0 \leq h \leq 1$ 이므로 Z 는 $\sigma(\eta)$ -measurable이며 integrable하다.

또한 $y \in [0, 1]$ 에서 $h(y)(\frac{1}{2} + y) = \frac{1}{3} + \frac{y}{2}$ 가 성립하므로 방금 계산을 거꾸로 읽으면 모든 Borel set B 에 대해

$$\int_{\{\eta \in B\}} Z dP = \int_{\{\eta \in B\}} \xi dP$$

이다. 이러한 사건들이 $\sigma(\eta)$ 의 모든 원소이므로 둘째 조건까지 확인되었다. 따라서

$$E(\xi \mid \eta) = h(\eta) \quad \text{a.s.}$$

이다. $\eta \in [0, 1]$ a.s.이므로 해당 구간에서는 위 유리식으로 값을 읽으면 된다.

앞의 예와 동일하게, 후보를 찾아낸 뒤에는 반드시 정의의 조건들을 확인했다. 교재의 다른 conditional expectation 계산 문제들도 이 순서를 연습하기에 좋다. 다음에는 관측변수 하나가 아니라 sigma-field 자체를 조건으로 주는 경우로 나아가자.

2.4 sigma-field를 조건으로 하는 경우

지금까지는 사건이나 random variable 하나를 조건으로 주었다. 실제로는 여러 번의 측정으로 얻은 정보를 함께 사용하거나 지금까지의 관측 이력 전체를 사용하고 싶을 수 있다. 그런 정보의 묶음을 표현하는 것이 sigma-field이다.

앞의 정의를 다시 보면, 조건으로 쓴 η 에서 실제로 사용한 것은 $\sigma(\eta)$ 였다. 후보 함수의 measurability를 판단할 때도, 적분을 비교할 사건을 고를 때도 이 sigma-field를 썼다. 그렇다면 이제 관측변수의 이름을 거치지 않고 정보 자체를 조건으로 주어도 되지 않을까?

Proposition 2.2. $\sigma(\eta) = \sigma(\eta')$ 이면 모든 $\xi \in L^1$ 에 대해

$$E(\xi \mid \eta) = E(\xi \mid \eta') \quad \text{a.s.}$$

이다.

Proof. 두 conditional expectation을 Z, Z' 라 하고 공통의 sigma-field를 $\mathcal{G}$ 라 쓰자. 둘은 integrable 하고 $\mathcal{G}$ -measurable이며, 모든 $A \in \mathcal{G}$ 에 대해

$$\int_A (Z - Z') dP = \int_A \xi dP - \int_A \xi dP = 0.$$

Lemma 2.1에 의해 $Z = Z'$ a.s.이다. □

관측값을 표현하는 방식이 달라도 생성하는 정보가 같으면 conditional expectation은 almost surely 같다. 이제 그 정보 자체를 정의에 넣자.

주어진 정보에 대한 conditional expectation의 정의

Definition (sigma-field에 대한 conditional expectation). $\xi \in L^1(\Omega, \mathcal{F}, P)$ 이고 $\mathcal{G} \subset \mathcal{F}$ 가 sigma-field라 하자. integrable한 random variable Z 가 다음 조건을 만족하면 $E(\xi \mid \mathcal{G})$ 라고 쓴다.

1. Z 는 $\mathcal{G}$ -measurable이다.
2. 모든 $A \in \mathcal{G}$ 에 대해

$$\int_A Z dP = \int_A \xi dP.$$

앞의 $\sigma(\eta)$ 를 주어진 $\mathcal{G}$ 로 바꾼 것뿐이다. 첫째 조건은 현재 정보로 결과를 알 수 있어야 한다는 조건이고, 둘째 조건은 그 정보에 속하는 사건마다 적분이 보존되어야 한다는 조건이다.

Remark: conditional probability와 이전 정의와의 일치. $A \in \mathcal{F}$ 에 대해

$$P(A \mid \mathcal{G}) = E(\mathbb{1}_A \mid \mathcal{G})$$

로 정의한다. 또한

$$E(\xi \mid \eta) = E(\xi \mid \sigma(\eta)) \quad \text{a.s.}$$

이다.

마지막 등식의 양변은 표기만 다르고 만족해야 하는 정의가 동일하다. 그래서 새 정의는 이전 정의와 일치하는 확장이다. conditional probability 역시 indicator function을 대입하는 같은 방식으로 확장되었다.

존재정리와 almost sure 유일성

Theorem 2.1: Radon–Nikodym theorem의 적용. sigma-field $\mathcal{G} \subset \mathcal{F}$ 와 $\xi \in L^1$ 에 대해, integrable하고 $\mathcal{G}$ -measurable인 random variable ζ 가 존재하여

$$\int_A \zeta dP = \int_A \xi dP \quad \text{모든 } A \in \mathcal{G}$$

를 만족한다.

이것이 conditional expectation의 존재를 보장하는 결과이다. Radon–Nikodym theorem은 더 일반적인 measure에 관한 정리이지만, 여기서는 위의 형태로 사용하고 증명은 하지 않겠다.

일반적인 맥락을 잠깐 연결해 보자. 보통 measure는 음이 아닌 값을 주지만, signed measure는 음수도 허용한다. 지금 $\mathcal{G}$ 의 사건에 대해

$$\nu(A) = \int_A \xi dP$$

로 두면 ξ 가 integrable하므로 유한 signed measure를 얻는다. 또 $P(A) = 0$ 이면 $\nu(A) = 0$ 이다. 이 성질을 ν 가 P 에 대해 absolutely continuous하다고 한다. 이 상황에서 Radon–Nikodym theorem은 ν 를 $\mathcal{G}$ -measurable인 함수의 적분으로 표현해 주며, 그 함수가 바로 위의 ζ 이다. 임의의 두 measure에 대해 아무 조건 없이 그런 표현이 존재한다는 말은 아니다.

Proposition 2.3. 모든 $\xi \in L^1$ 과 sigma-field $\mathcal{G} \subset \mathcal{F}$ 에 대해 $E(\xi | \mathcal{G})$ 가 존재하고, a.s. 같다는 의미에서 유일하다.

존재는 방금 정리에서, 유일성은 두 후보의 차이에 Lemma 2.1을 적용하여 얻는다. 따라서 앞으로는 정의를 만족하는 후보 하나를 찾으면 그것이 conditional expectation의 한 대표라고 결론낼 수 있다.

정보가 없을 때와 이미 값을 알 때

Exercise 2.10.

$$E(\xi | \{\emptyset, \Omega\}) = E(\xi) \quad \text{a.s.}$$

가장 작은 sigma-field는 서로 다른 결과들을 구별하는 정보를 주지 않는다. 따라서 전체 평균이라는 상수가 나오는 것이 자연스럽다. 실제로 $c = E(\xi)$ 를 상수함수로 생각하면 integrable하고 $\{\emptyset, \Omega\}$ -measurable이다. 시험할 사건은 둘뿐이며,

$$\int_{\emptyset} c dP = 0 = \int_{\emptyset} \xi dP, \quad \int_{\Omega} c dP = c = E(\xi) = \int_{\Omega} \xi dP.$$

따라서 c 가 정의를 만족한다. 오른쪽은 수치이지만 왼쪽의 random variable은 그 값을 갖는 상수 함수라는 뜻이다.

Exercise 2.11. $\xi \in L^1$ 이 $\mathcal{G}$ -measurable이면

$$E(\xi | \mathcal{G}) = \xi \quad \text{a.s.}$$

이다.

이번에는 현재 정보로 ξ 를 이미 알 수 있다. 후보를 ξ 자체로 놓으면 integrability와 $\mathcal{G}$ -measurability가 가정에 들어 있고, 모든 $A \in \mathcal{G}$ 에서

$$\int_A \xi dP = \int_A \xi dP$$

이므로 적분 조건도 만족한다. 정보를 전혀 주지 않는 경우의 상수 평균과, 이미 모든 필요한 정보를 주는 경우의 원래 변수를 비교해 보자.

conditional expectation을 다시 한 사건에서 평균내기

Exercise 2.12. $B \in \mathcal{G}$ 이고 $P(B) > 0$ 이면

$$E(E(\xi | \mathcal{G}) | B) = E(\xi | B).$$

먼저 $\mathcal{G}$ 로 조건을 준 결과는 random variable이므로 다시 B 에서 평균낼 수 있다. 계산은

$$E(E(\xi | \mathcal{G}) | B) = \frac{1}{P(B)} \int_B E(\xi | \mathcal{G}) dP = \frac{1}{P(B)} \int_B \xi dP$$

이다. 두 번째 등식을 사용할 수 있는 이유는 B 가 바로 $\mathcal{G}$ 의 사건이기 때문이다. 마지막 결과는 $E(\xi | B)$ 이다.

최종적으로 B 에서 평균낸 수치는 처음부터 ξ 를 그 사건에서 평균낸 것과 같다. 여기서 B 는 sigma-field가 아니라 사건이고 최종 결과는 실수이다. sigma-field로 연달아 조건을 주는 경우는 다음의 tower property에서 정확히 다루자. 이런 반복 조건화는 뒤의 martingale과 stochastic process에서 자주 만나게 된다.

2.5 일반 성질

Proposition 2.4. $\xi, \zeta \in L^1$, $a, b \in \mathbb{R}$ 이고 $\mathcal{H} \subset \mathcal{G} \subset \mathcal{F}$ 가 sigma-field들이라 하자.

1. linearity:

$$E(a\xi + b\zeta \mid \mathcal{G}) = aE(\xi \mid \mathcal{G}) + bE(\zeta \mid \mathcal{G}) \quad \text{a.s.}$$

2. 전체 expectation 보존:

$$E(E(\xi \mid \mathcal{G})) = E(\xi).$$

3. ξ 가 $\mathcal{G}$ -measurable이고 $\xi \in L^1$ 이면

$$E(\xi \mid \mathcal{G}) = \xi \quad \text{a.s.}$$

4. ξ 가 $\mathcal{G}$ 와 independent이면

$$E(\xi \mid \mathcal{G}) = E(\xi) \quad \text{a.s.}$$

5. tower property:

$$E(E(\xi \mid \mathcal{G}) \mid \mathcal{H}) = E(\xi \mid \mathcal{H}) \quad \text{a.s.}$$

6. $\xi \geq 0$ a.s.이면 $E(\xi \mid \mathcal{G}) \geq 0$ a.s.이다.

random variable들 사이의 등식은 almost sure 등식이다. 반면 둘째 항은 적분을 끝낸 실수끼리의 등식이므로 a.s.라는 단서를 붙일 대상이 아니다.

셋째 항은 현재 정보로 알고 있는 인자를 conditional expectation 밖으로 꺼낼 수 있다는 성질이다. 그렇지만 두 변수가 각각 integrable하다고 곱도 자동으로 integrable한 것은 아니므로 곱에 대한 가정을 확인해야 한다. 넷째 항은 independent인 정보로는 평균을 바꾸지 않는다는 뜻이다. tower property에서는 큰 정보로 조건을 준 뒤 작은 정보로 다시 평균내면 작은 정보에 대한 결과가 남는다.

마지막 비음성 성질과 linearity를 결합하면 monotonicity도 얻는다. $\xi_1 \geq \xi_2$ a.s.이면 차이 $\xi_1 - \xi_2$ 에 적용하여

$$E(\xi_1 \mid \mathcal{G}) \geq E(\xi_2 \mid \mathcal{G}) \quad \text{a.s.}$$

이다. 이제 각 성질을 정의로 확인하자.

linearity와 전체 expectation의 보존

증명에서

$$X = E(\xi \mid \mathcal{G}), \quad Z = E(\zeta \mid \mathcal{G})$$

로 쓰자. 첫째 성질에서는 $aX + bZ$ 가 $a\xi + b\zeta$ 의 conditional expectation인지 확인한다. 이 후보는 integrable하고 $\mathcal{G}$ -measurable이다. 모든 $A \in \mathcal{G}$ 에 대해

$$\begin{aligned} \int_A (aX + bZ) dP &= a \int_A X dP + b \int_A Z dP \\ &= a \int_A \xi dP + b \int_A \zeta dP \\ &= \int_A (a\xi + b\zeta) dP. \end{aligned}$$

첫 줄과 마지막 줄은 적분의 linearity이고, 가운데 줄에서 X, Z 의 정의를 각각 사용했다. 따라서 후보가 두 조건을 만족하며 a.s. 유일성에 의해 첫째 성질이 성립한다.

둘째 성질은 시험 사건으로 $A = \Omega$ 를 고르면 된다.

$$E(X) = \int_{\Omega} X dP = \int_{\Omega} \xi dP = E(\xi).$$

conditional expectation을 취하면 함숫값은 바뀔 수 있지만, 전체 공간에서 평균낸 수치는 바뀌지 않는다.

음이 아닌 변수를 조건화해도 음이 되지 않는다

셋째 성질은 근사 과정이 필요하므로, 먼저 여섯째 성질부터 확인하자. $\xi \geq 0$ a.s.라고 가정하고 $X \geq 0$ a.s.를 보이려면 $P(X < 0) = 0$ 임을 보이면 된다.

$$A_n = \{X \leq -1/n\} \in \mathcal{G}$$

로 두자. X 의 $\mathcal{G}$ -measurability 덕분에 정의의 적분 등식에 이 사건을 넣을 수 있다. 그러면

$$0 \leq \int_{A_n} \xi dP = \int_{A_n} X dP \leq -\frac{1}{n}P(A_n).$$

왼쪽의 비음성은 $\xi \geq 0$ a.s.에서, 오른쪽의 상계는 A_n 의 정의에서 왔다. 끝의 표현은 음이 아니면서 동시에 0 이하이므로 $P(A_n) = 0$ 이다.

마지막으로

$$\{X < 0\} = \bigcup_{n \geq 1} A_n$$

이므로 countable subadditivity를 적용하면 $P(X < 0) = 0$ 이다. 앞서 유일성을 증명할 때처럼 level set마다 적분을 시험하고 countable union으로 almost sure 결론을 얻었다.

알고 있는 인자를 꺼내기: 쉬운 함수부터

이제 ξ 가 $\mathcal{G}$ -measurable이고 $\xi\zeta \in L^1$ 일 때

$$E(\xi\zeta \mid \mathcal{G}) = \xi Z \quad \text{a.s.}$$

임을 보이자. indicator function, simple function, bounded function, 일반적인 함수의 순서로 간다.

먼저 $\xi = \mathbb{1}_A$, $A \in \mathcal{G}$ 라 하자. $\mathbb{1}_A Z$ 는 $\mathcal{G}$ -measurable이고 $|\mathbb{1}_A Z| \leq |Z|$ 이므로 integrable하다. 모든 $B \in \mathcal{G}$ 에 대해

$$\begin{aligned} \int_B \mathbb{1}_A Z dP &= \int_{B \cap A} Z dP \\ &= \int_{B \cap A} \zeta dP \\ &= \int_B \mathbb{1}_A \zeta dP. \end{aligned}$$

가운데 등식에서 $B \cap A \in \mathcal{G}$ 가 필요하다. 단순히 $A \in \mathcal{F}$ 라는 사실만으로는 사용할 수 없다. 따라서 indicator function인 경우 정의의 조건들을 확인했다.

$\mathcal{G}$ -measurable인 simple function은 이러한 indicator function들의 유한 linear combination으로 쓸 수 있다. 이미 증명한 linearity를 적용하면 simple function인 경우도 얻는다.

다음으로 $|\xi| \leq M$ 인 $\mathcal{G}$ -measurable function을 생각하자. ξ 를 점별로 근사하는 simple function s_m 을 $|s_m| \leq M$ 이 되도록 잡을 수 있다. simple function의 경우에서

$$\int_B s_m Z dP = \int_B s_m \zeta dP$$

를 알고 있다. 양쪽 적분함수는 각각 $M|Z|$ 와 $M|\zeta|$ 로 지배되며, 이 함수들은 integrable하다.

여기서 **dominated convergence theorem**을 사용한다. 함수열이 점별로 수렴하고 절댓값이 하나의 integrable한 함수로 공통으로 지배되면, 적분과 극한을 교환할 수 있다는 정리이다. 따라서

$$\int_B \xi Z dP = \int_B \xi \zeta dP$$

를 얻는다. ξZ 의 measurability와 integrability도 boundedness에서 따라오므로 bounded function인 경우까지 증명했다. conditional expectation 기호 안에서 극한을 임의로 옮긴 것이 아니라, 정의를 이루는 적분들에서 dominated convergence를 적용한 것이다.

일반적인 인자: integrability를 먼저 확보하기

이제 ξ 가 bounded라고 가정하지 않겠다. 여전히 ξ 는 $\mathcal{G}$ -measurable이고 $\xi\zeta \in L^1$ 이다. 목표인 ξZ 의 measurability는 알 수 있지만 integrability는 아직 확인하지 않았다. 그것부터 확보해야 conditional expectation의 후보가 된다.

다음 보조함수를 만들자.

$$H_n = (|\xi| \wedge n) \operatorname{sgn}(Z).$$

$u \wedge v$ 는 두 값의 최솟값이다. $\operatorname{sgn}(z)$ 는 $z > 0$ 일 때 1, $z < 0$ 일 때 -1, $z = 0$ 일 때 0이다. 따라서 H_n 은 $\mathcal{G}$ -measurable이며 $|H_n| \leq n$ 인 bounded function이다.

부호함수를 곱한 이유는 $\operatorname{sgn}(Z)Z = |Z|$ 를 만들기 위해서이다. bounded function에 대해 방금 증명한 성질과 전체 expectation 보존을 순서대로 적용하면

$$\begin{aligned} E((|\xi| \wedge n)|Z|) &= E(H_n Z) \\ &= E(E(H_n \zeta \mid \mathcal{G})) \\ &= E(H_n \zeta) \\ &\leq E(|\xi \zeta|) < \infty. \end{aligned}$$

마지막 부등식은 $|H_n \zeta| \leq |\xi \zeta|$ 에서 나온다. H_n 이 bounded이므로 중간의 $H_n \zeta$ 도 integrable하여 각 expectation이 정의된다.

왼쪽의 음이 아닌 함수 $(|\xi| \wedge n)|Z|$ 는 n 이 증가하면 $|\xi Z|$ 로 증가한다. 음이 아닌 증가 함수열의 적분과 극한을 교환하는 monotone convergence theorem에 의해

$$E(|\xi Z|) = \lim_{n \rightarrow \infty} E((|\xi| \wedge n)|Z|) \leq E(|\xi \zeta|) < \infty.$$

이렇게 ξZ 의 integrability를 얻었다. 오른쪽 상계가 n 에 의존하지 않는다는 것이 핵심이다.

이제 적분 보존 조건을 증명하자. 이번에는 양쪽에서 자른 함수

$$\xi_n = (-n) \vee (\xi \wedge n)$$

를 사용한다. $u \vee v$ 는 최댓값이다. ξ_n 은 $[-n, n]$ 안에 있고, $\xi_n \rightarrow \xi$ 가 점별로 성립한다. bounded function의 경우를 적용하면 모든 $B \in \mathcal{G}$ 에서

$$\int_B \xi_n Z dP = \int_B \xi_n \zeta dP.$$

극한을 취하기 전에 dominating function을 확인해야 한다.

$$|\xi_n Z| \leq |\xi Z| \in L^1, \quad |\xi_n \zeta| \leq |\xi \zeta| \in L^1.$$

첫 integrability는 방금 증명했고, 둘째는 원래의 가정이다. 따라서 양쪽에 dominated convergence theorem을 적용하여

$$\int_B \xi Z dP = \int_B \xi \zeta dP$$

를 얻는다. ξZ 는 measurable이고 integrable하며 모든 시험 사건에서 이 등식을 만족하므로, a.s. 유일성에 의해 셋째 성질이 증명되었다.

두 번 자른 이유를 구별해 두자. 첫 절단에서는 부호함수를 함께 사용하여 후보 ξZ 의 absolute integrability를 먼저 확보했다. 둘째 절단에서는 그 결과로 얻은 integrable한 상계를 이용해 적분 등식에서 극한을 통과시켰다. 곱의 integrability를 확인하기 전에 둘째 계산부터 시작하면 이 연결이 빠진다.

independent인 정보와 tower property

넷째 성질에서 ξ 는 $\mathcal{G}$ 와 independent이다. 후보를 상수 $E(\xi)$ 로 놓자. 이 함수는 integrable하고 $\mathcal{G}$ -measurable이다. $A \in \mathcal{G}$ 이면 ξ 와 $\mathbb{1}_A$ 가 independent이며, $|\xi \mathbb{1}_A| \leq |\xi|$ 이므로 곱도 integrable하다. 따라서

$$\int_A E(\xi) dP = E(\xi)P(A) = E(\xi \mathbb{1}_A) = \int_A \xi dP.$$

모든 조건이 확인되었으므로 $E(\xi | \mathcal{G}) = E(\xi)$ a.s.이다. $\mathcal{G}$ 가 ξ 에 관한 추가 정보를 주지 않으므로 원래 평균을 그대로 사용한다. ξ 가 이미 $\mathcal{G}$ -measurable인 경우의 결과 ξ 와 혼동하지 말자.

마지막으로 tower property를 보자. $\mathcal{H} \subset \mathcal{G}$ 이고

$$W = E(E(\xi | \mathcal{G}) | \mathcal{H})$$

라 두면 W 는 integrable하고 $\mathcal{H}$ -measurable이다. 임의의 $A \in \mathcal{H}$ 는 $\mathcal{G}$ 에도 속하므로

$$\int_A W dP = \int_A E(\xi | \mathcal{G}) dP = \int_A \xi dP.$$

첫 등식은 $\mathcal{H}$ 에 대한 conditional expectation의 정의, 둘째는 $\mathcal{G}$ 에 대한 정의이다. 같은 사건을 두 정의에 모두 넣을 수 있게 해 주는 것이 포함관계 $\mathcal{H} \subset \mathcal{G}$ 이다. 따라서 W 가 $E(\xi | \mathcal{H})$ 의 정의를 만족하여

$$E(E(\xi | \mathcal{G}) | \mathcal{H}) = E(\xi | \mathcal{H}) \quad \text{a.s.}$$

를 얻는다.

순서를 바꾸어도 작은 정보에 대한 결과가 남는다.

$$E(E(\xi | \mathcal{H}) | \mathcal{G}) = E(\xi | \mathcal{H}) \quad \text{a.s.}$$

이번에는 안쪽의 변수가 이미 $\mathcal{H}$ -measurable이므로 $\mathcal{G}$ -measurable이기도 하다는 사실과 Exercise 2.11을 사용한다. 두 방향의 결론은 같지만 증명에서 사용하는 이유는 구별된다.

선형 성질 다음에 볼 것

이번 성질들은 주로 linear combination, 적분의 보존, 이미 알고 있는 인자의 분리처럼 선형적인 연산을 다뤘다. nonlinear 함수를 적용하면 등식이 그대로 유지되지는 않지만, 부등식의 형태로 얻을 수 있는 성질들이 있다. 다음에는 convex function과 conditional expectation의 관계를 살펴보자. 구체적인 conditional expectation을 구하는 교재의 연습문제들도 정의를 사용하는 연습으로 이어가자.

conditional expectation과 nonlinear 함수

지난 시간에는 conditional expectation의 linearity와 tower property 등을 보았다. 이번에는 nonlinear 함수를 적용하면 어떤 일이 생기는지 보자. integrable한 ξ 에 대해서는

$$\left| \int \xi dP \right| \leq \int |\xi| dP$$

가 성립한다. 그렇다면 적분 대신 conditional expectation을 넣어도

$$|E(\xi | \mathcal{G})| \leq E(|\xi| | \mathcal{G}) \quad \text{a.s.}$$

가 성립할까? 여기서 $\mathcal{G} \subseteq \mathcal{F}$ 는 주어진 정보를 나타내는 sigma-field이다.

보통의 expectation을 계산하면 수 하나가 나온다. 하지만 conditional expectation을 계산하면 여전히 random variable이 남는다. 따라서 지금 비교하려는 것은 두 수가 아니라 두 함수이고, 부등식도 almost surely 성립한다는 형태로 써야 한다. 더욱이 conditional expectation은 명시적인 계산식이 아니라 사건별 적분 조건으로 정의했다. 두 함수를 직접 계산해서 비교하기보다는, 이미 알고 있는 linearity와 monotonicity를 사용할 방법을 찾아야 한다. 그 연결을 해 주는 것이 convexity이다.

Definition (convex function). 함수 $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 가 모든 $x, y \in \mathbb{R}$ 와 $\lambda \in [0, 1]$ 에 대해

$$\varphi(\lambda x + (1 - \lambda)y) \leq \lambda\varphi(x) + (1 - \lambda)\varphi(y)$$

를 만족하면 convex function이라고 한다.

x 와 y 사이의 점 $\lambda x + (1 - \lambda)y$ 를 생각해 보자. 왼쪽은 그 점에서의 함수값이고, 오른쪽은 그래프 위의 두 점을 연결한 선분의 높이이다. convex하다는 것은 그래프가 이 선분보다 위로 올라가지 않는다는 뜻이다. $x \mapsto |x|$ 의 V자 모양 그래프가 한 예이다.

conditional Jensen's inequality: 곡선을 직선들로 바꾸기

Theorem 2.2 (conditional Jensen's inequality). $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 가 convex하고 $\xi, \varphi(\xi) \in L^1$ 이면

$$\varphi(E(\xi | \mathcal{G})) \leq E(\varphi(\xi) | \mathcal{G}) \quad \text{a.s.}$$

이다.

두 integrability 조건의 역할을 구별하자. 왼쪽의 $E(\xi | \mathcal{G})$ 를 정의하려면 $\xi \in L^1$ 이 필요하다. 오른쪽의 conditional expectation을 정의하려면 $\varphi(\xi) \in L^1$ 도 필요하다.

Proof. 핵심은 convex function을 그 아래의 affine function들로 표현하는 것이다. affine function은 $ax + b$ 꼴의 함수이다. 그래프의 한 점을 지나면서 전체 그래프 아래에 놓이는 직선을 supporting line이라고 하자. 매끄러운 convex function이라면 접선을 떠올리면 되지만, 이 논의에 미분가능성을 가정하지는 않는다.

유리수를 $q_1, q_2, \dots$ 로 나열하고, 각 q_k 에서 supporting line $a_k x + b_k$ 를 하나씩 택한다. 그러면

$$a_k x + b_k \leq \varphi(x), \quad a_k q_k + b_k = \varphi(q_k), \quad \varphi(x) = \sup_{k \geq 1} (a_k x + b_k).$$

마지막 식은 모든 점에서 지지하는 직선을 다 고를 필요가 없다는 뜻이다. 유리수 지점의 supporting line만 택해도 그 상한으로 원래 그래프를 회복한다. 이렇게 선택한 직선들의 모임은 countable하다.

이 표현의 이유를 조금 살펴보자. 유한값 convex function은 실수축의 내부에서 연속이고, 한 점의 왼쪽 할선 기울기들과 오른쪽 할선 기울기들 사이에서 supporting line의 기울기를 택할 수 있다. 고정된 x 로 유리수 q_k 를 가까이 보내면, 주변의 두 고정된 점으로 만든 할선 기울기가 그 supporting line들의 기울기를 위아래에서 제한한다. 따라서

$$a_k x + b_k = \varphi(q_k) + a_k(x - q_k) \longrightarrow \varphi(x)$$

가 되도록 유리수들을 택할 수 있다. 모든 supporting line은 원래 함수보다 아래에 있으므로 그 상한은 정확히 $\varphi(x)$ 이다.

이제 nonlinear 함수를 한 번에 다루지 말고 k 를 하나 고정하자. $a_k \xi + b_k \leq \varphi(\xi)$ 이고, $\xi \in L^1$ 이므로 이 affine function도 integrable하다. conditional expectation의 linearity와 monotonicity를 차례로 적용하면

$$a_k E(\xi | \mathcal{G}) + b_k = E(a_k \xi + b_k | \mathcal{G}) \leq E(\varphi(\xi) | \mathcal{G}) \quad \text{a.s.}$$

이다. nonlinear 문제를 이미 알고 있는 두 성질로 바꾼 셈이다.

여기서 곧바로 상한을 취하기 전에 “almost surely”라는 말을 확인해야 한다. 각 k 의 부등식에는 실패할 수 있는 null set N_k 가 있다. 선택한 supporting line들의 모임이 countable하므로

$$N = \bigcup_{k=1}^{\infty} N_k, \quad P(N) \leq \sum_{k=1}^{\infty} P(N_k) = 0.$$

N 밖에서는 모든 k 의 부등식이 동시에 성립한다. 유리수들을 택한 것이 바로 이 단계에 쓰인다. uncountable한 모임을 이루는 null set들의 합집합까지 확률이 0이라고 할 수는 없다.

그 공통의 확률 1인 집합 위에서 상한을 취하면

$$\begin{aligned}\varphi(E(\xi | \mathcal{G})) &= \sup_{k \geq 1} \{a_k E(\xi | \mathcal{G}) + b_k\} \\ &\leq E(\varphi(\xi) | \mathcal{G}).\end{aligned}$$

오른쪽은 k 에 의존하지 않으므로 모든 affine function의 공통 상계로 남는다. 이것으로 증명이 끝난다. 이 과정에서 상한을 conditional expectation 안으로 옮긴 것은 아니다. $\square$

절댓값과 p 제곱에 적용하기

먼저 $\varphi(x) = |x|$ 를 넣으면 처음의 질문에 답을 얻는다.

$$|E(\xi | \mathcal{G})| \leq E(|\xi| | \mathcal{G}) \quad \text{a.s.}$$

$\xi \in L^1$ 이면 $|\xi|$ 도 integrable하므로 정리의 두 조건이 모두 충족된다.

또 $1 \leq p < \infty$ 이고 $\xi \in L^p$, 즉 $E|\xi|^p < \infty$ 라고 하자. probability space에서는 $|\xi| \leq 1 + |\xi|^p$ 이므로 $\xi \in L^1$ 도 따른다. convex function $\varphi(x) = |x|^p$ 에 Jensen's inequality를 적용하면

$$|E(\xi | \mathcal{G})|^p \leq E(|\xi|^p | \mathcal{G}) \quad \text{a.s.}$$

이다. 두 변이 아직 random variable이라는 점을 기억하자. 여기에 expectation을 한 번 더 취하면

$$E(|E(\xi | \mathcal{G})|^p) \leq E(E(|\xi|^p | \mathcal{G})) = E|\xi|^p.$$

오른쪽이 유한하므로 왼쪽의 integrability도 이 부등식에서 함께 얻는다. 마지막 등식은 전체 expectation 보존 성질이다. conditional expectation을 취한 뒤에도 p 제곱 적분이 커지지 않는다는 결론이다.

3. discrete time martingale

conditional expectation의 성질은 여기까지 보고, 2.6절의 연습문제로 계산에 익숙해지면 좋다. 이제 discrete time stochastic process를 다룬다. 나중에 6장에서는 continuous time stochastic process를 다루지만, 지금의 시간은 $1, 2, 3, \dots$ 처럼 한 단계씩 진행한다.

동전 던지기 같은 게임을 여러 번 반복한다고 생각해 보자. 어떤 때는 돈을 얻고 어떤 때는 잃는다. martingale은 이런 과정에서 공정한 게임을 수학적으로 표현하는 모형이다. 공정하다는 말은 매번 실제 수익이 0이라는 뜻이 아니라, 현재 정보에 비추어 예상하는 다음 수익에 관한 말이다. 앞으로는 이 의미를 정의하고, 판마다 돈을 다르게 거는 전략도 살펴보자.

3.1 random variable들의 열과 sample path

한 번의 게임을 random variable 하나로 나타냈다면, 반복되는 게임은 같은 probability space $(\Omega, \mathcal{F}, P)$ 위에 정의된 random variable들의 열

$$\xi_n : \Omega \rightarrow \mathbb{R}, \quad n \geq 1$$

로 나타낼 수 있다.

Definition (sample path). 결과 $\omega \in \Omega$ 하나를 고정했을 때 얻는 실수열

$$\xi_1(\omega), \xi_2(\omega), \dots$$

을 (ξ_n) 의 sample path라고 한다.

ξ_n 은 함수이고 $\xi_n(\omega)$ 는 그 함수의 실현값이다. 반복되는 동전 던지기의 전체 결과 하나를 고정하고 앞면을 1, 뒷면을 0으로 표시하면, 그 결과에 대응하는 0과 1의 수열이 sample path이다. 이번 절에서는 이 구별을 먼저 기억하면 된다.

3.2 filtration과 지금까지의 정보

Definition (filtration). sigma-field들의 열 $(\mathcal{F}_n)$ 이

$$\mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \cdots \subseteq \mathcal{F}$$

를 만족하면 filtration이라고 한다.

각 $\mathcal{F}_n$ 은 전체 사건들의 sigma-field $\mathcal{F}$ 안에 있다. 시간이 지날수록 관측이 쌓이고, 이미 얻은 정보는 잃지 않는다는 모습을 포함관계로 나타낸다.

Example 3.1. 무한 동전열 $\Omega = \{H, T\}^{\mathbb{N}}$ 에서 n 번째 앞면을 $\xi_n = 1$, 뒷면을 $\xi_n = 0$ 으로 표시하고

$$\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$$

으로 두자. A 를 처음 다섯 번 중 앞면이 적어도 두 번 나오는 사건이라 하면

$$A \in \mathcal{F}_5, \quad A \notin \mathcal{F}_4.$$

다섯 번을 모두 관측하면 A 의 발생 여부를 판단할 수 있으므로 $A \in \mathcal{F}_5$ 이고, 포함관계에 의해 $\mathcal{F}_6, \mathcal{F}_7, \dots$ 에도 속한다. 하지만 네 번의 결과가 $THTT$ 라면 어떤가? 다섯 번째가 H 일 때는 A 가 발생하고 T 일 때는 발생하지 않는다. 첫 네 관측만 같은 두 결과를 구별해야 하므로 $A \notin \mathcal{F}_4$ 이다.

반대로 처음 네 번이 $THTH$ 이면 이미 앞면이 두 번 나왔다. 그 경로에서는 다섯 번째 결과와 관계없이 A 가 발생한다는 것을 안다. 그런데 이것만으로 $A \in \mathcal{F}_4$ 라고 할 수는 없다. sigma-field에 속한다는 것은 특정한 경로에서 우연히 답을 알 수 있다는 뜻이 아니라, 첫 네 관측이 주어지면 모든 경우에 발생 여부를 판별할 수 있다는 뜻이다. 이 예의 $\mathcal{F}_n$ 의 사건들은 첫 n 번 결과가 같은 무한 동전열들을 구별하지 못한다.

사건을 판별할 수 있는 가장 이른 시점

Exercise 3.1. 위 동전열에서 다음 사건이 $\mathcal{F}_n$ 에 속하는 가장 작은 $n \geq 1$ 을 구하여라. 그런 유한한 n 이 없을 수도 있다.

1. A : 첫 앞면 전에 뒷면이 열 번 이하 나온다.
2. B : 무한한 동전열 어딘가에서 앞면이 한 번 이상 나온다.
3. C : 처음 백 번의 결과가 모두 같다.
4. D : 처음 다섯 번에서 앞면이 두 번 이하이고 뒷면도 두 번 이하이다.

먼저 각 답을 생각해 보자. 어떤 시점에 사건이 속한다는 것과 그 시점이 가장 이르다는 것은 별도로 확인해야 한다.

A 의 조건은 처음 열한 번 중 앞면이 적어도 한 번 있다는 뜻이므로

$$A = \bigcup_{k=1}^{11} \{\xi_k = 1\} \in \mathcal{F}_{11}.$$

각 사건은 $\mathcal{F}_k$ 에 속하고 $k \leq 11$ 이면 $\mathcal{F}_k \subseteq \mathcal{F}_{11}$ 이므로 합집합도 $\mathcal{F}_{11}$ 에 속한다.

이 식이 바로 와닿지 않으면 첫 앞면의 위치를 나열해 보자. $H \dots, TH \dots, TTH \dots$, 그리고 마지막으로 $T^{10}H \dots$ 가 가능하다. 각 접두부 뒤의 점들은 이후의 결과가 무엇이든 상관없다는 뜻이다. 따라서 접두부 하나는 단일한 결과가 아니라 수많은 무한 동전열을 나타낸다. 이 경우들을 합친 것이 위의 간단한 합집합이다.

열 번 연속 T 가 나왔을 때는 아직 결론을 내릴 수 없다. 열한 번째 H 는 A 를 성립시키고, T 는 실패하게 한다. 따라서 $A \notin \mathcal{F}_{10}$ 이며 최소 시점은 11이다. 더 이전의 sigma-field는 모두 $\mathcal{F}_{10}$ 안에 있으므로 그때도 속하지 않는다.

B 에서는 어떤 유한한 n 을 택해도 처음 n 번이 모두 T 인 경우를 생각할 수 있다. 그 뒤에 H 가 나오는 결과와 영원히 T 만 나오는 결과는 첫 n 번 관측이 같지만 B 의 발생 여부는 다르다. 그러므로

$$B \notin \mathcal{F}_n \quad \text{모든 유한한 } n.$$

이미 앞면을 본 경로에서는 답을 알지만, 모든 경로의 답을 유한한 한 시점에 결정할 수는 없다. 이는 사건의 정확한 집합 소속에 관한 논의이다.

C 는 앞면만 백 번 또는 뒷면만 백 번 나오는 경우이다.

$$C = \{\xi_1 = \cdots = \xi_{100} = 1\} \cup \{\xi_1 = \cdots = \xi_{100} = 0\} \in \mathcal{F}_{100}.$$

하지만 앞면이 아흔아홉 번 나온 뒤에는 마지막 한 번에 따라 결론이 달라진다. 그래서 $C \notin \mathcal{F}_{99}$ 이고 최소 시점은 100이다.

D 는 발생할 수 없다. 앞면 수와 뒷면 수를 더하면 반드시 5인데, 둘 다 2 이하이면 합이 4 이하가 되기 때문이다. 따라서 $D = \emptyset$ 이고 모든 sigma-field에 속한다. 문제의 범위가 $n \geq 1$ 이므로 최소값은 1이다.

adaptedness: random variable과 filtration의 관계

지금까지 random variable들의 열과 filtration을 각각 정의했다. filtration의 정의만 보면 특정 random variable들의 열이 등장하지 않는다. 두 대상을 연결하려면 별도의 조건이 필요하다.

Definition (adaptedness). 모든 $n \geq 1$ 에서 ξ_n 이 $\mathcal{F}_n$ -measurable이면 (ξ_n) 이 $(\mathcal{F}_n)$ 에 adapted라고 한다.

이는 시점 n 의 정보로 그 시점의 값 ξ_n 을 알 수 있어야 한다는 조건이다.

Example 3.2. 모든 random variable들의 열 (ξ_n) 은 자신의 natural filtration

$$\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$$

에 adapted이다.

생성 sigma-field의 정의에 의해 ξ_n 은 $\mathcal{F}_n$ -measurable이다. 또 생성에 사용한 변수가 늘어나므로 $(\mathcal{F}_n)$ 은 실제로 filtration이다.

natural filtration이 가장 작다는 뜻

natural filtration만이 가능한 filtration은 아니다. 더 많은 정보를 넣은 filtration에도 같은 random variable들의 열이 adapted일 수 있다. natural filtration은 그중 필요한 정보만 담은 가장 작은 filtration이다.

Exercise 3.2. (ξ_n) 이 filtration $(\mathcal{G}_n)$ 에 adapted이면

$$\sigma(\xi_1, \dots, \xi_n) \subseteq \mathcal{G}_n \quad \text{모든 } n \geq 1$$

임을 보여라.

Proof. n 을 고정하고 $k \leq n$ 을 택하자. adaptedness에 의해 ξ_k 는 $\mathcal{G}_k$ -measurable이다. filtration의 포함관계 $\mathcal{G}_k \subseteq \mathcal{G}_n$ 에 의해 ξ_k 는 $\mathcal{G}_n$ -measurable이기도 하다. 구체적으로 모든 Borel set B 에 대해

$$\{\xi_k \in B\} \in \mathcal{G}_k \subseteq \mathcal{G}_n.$$

따라서 $\mathcal{G}_n$ 은 $\xi_1, \dots, \xi_n$ 을 모두 measurable하게 만든다. 이 변수들을 measurable하게 만드는 가장 작은 sigma-field가 $\sigma(\xi_1, \dots, \xi_n)$ 이므로 원하는 포함관계가 따른다. $\square$

공정한 게임의 정의로 이어가기

다음에 공부할 martingale의 조건을 먼저 살펴보자. 각 ξ_n 이 integrable하고, 열이 주어진 filtration에 adapted이며,

$$E(\xi_{n+1} | \mathcal{F}_n) = \xi_n \quad \text{a.s.}$$

이면 martingale이라고 한다. integrability는 conditional expectation을 정의하기 위해, adaptedness는 현재 값과 현재 정보를 연결하기 위해 필요하다. 마지막 등식은 지금까지의 정보를 모두 사용해 다음 값을 예상해도 현재 값과 같다는 공정성의 조건이다. filtration은 꼭 natural filtration일 필요는 없다. 다음에는 예제를 통해 이 세 조건을 확인하고, 등식을 부등식으로 바꾼 경우도 살펴보자.

3.3 martingale

먼저 지난 시간 끝에 본 정의를 다시 정리하자. random variable들의 열 (ξ_n) 과 filtration $(\mathcal{F}_n)$ 이 주어져 있다. filtration은 시간이 흐르면서 증가하는 정보이고, 이 정보에 비추어 공정한 게임을 나타내려는 것이 우리의 목표이다.

Definition (martingale). (ξ_n) 이 filtration $(\mathcal{F}_n)$ 에 대한 martingale이라는 것은 모든 $n \geq 1$ 에 대해 다음 세 조건을 만족한다는 뜻이다.

1. $\xi_n \in L^1$ 이다.
2. ξ_n 은 $\mathcal{F}_n$ -measurable이다. 즉 열이 filtration에 adapted이다.
3. $E(\xi_{n+1} | \mathcal{F}_n) = \xi_n$ a.s.이다.

시간을 0부터 시작하면 같은 조건을 $n \geq 0$ 에 대해 적용한다.

핵심은 세 번째 조건이다. 현재까지 관측한 정보를 모두 사용해서 다음 값을 예상해도, 그 conditional expectation이 현재 값과 같다는 뜻이다. 실제 다음 값은 달라질 수 있다. 이제 예제마다 먼저 integrability와 adaptedness를 확인하고, 마지막으로 이 등식을 계산해 보자.

independent인 평균 0의 변화량을 더하기

Example 3.3. (η_n) 이 independent인 integrable한 random variable들의 열이고 모든 n 에 대해 $E\eta_n = 0$ 이라고 하자. 이때

$$\xi_n = \sum_{k=1}^n \eta_k, \quad \mathcal{F}_n = \sigma(\eta_1, \dots, \eta_n)$$

으로 정의한 (ξ_n) 은 $(\mathcal{F}_n)$ 에 대한 martingale이다.

각 η_n 은 한 번의 게임에서 생기는 수익이고, ξ_n 은 지금까지의 누적 수익이라고 생각하면 된다. 새로운 게임의 결과가 이전 결과들과 independent이며 평균 수익은 0이다. 여기서는 모든 η_n 의 distribution이 같다고 가정할 필요는 없다.

Proof. $k \leq n$ 인 η_k 들은 모두 $\mathcal{F}_n$ -measurable이므로 그 합 ξ_n 도 $\mathcal{F}_n$ -measurable이다. 또 삼각부등식에 의해

$$E|\xi_n| \leq \sum_{k=1}^n E|\eta_k| < \infty.$$

n 을 고정하면 integrable한 변수의 유한합이므로 integrability가 확보된다.

마지막 조건을 위해 합의 마지막 항을 떼어 내자.

$$\xi_{n+1} = \xi_n + \eta_{n+1}.$$

conditional expectation의 linearity를 쓰면

$$E(\xi_{n+1} | \mathcal{F}_n) = E(\xi_n | \mathcal{F}_n) + E(\eta_{n+1} | \mathcal{F}_n).$$

첫 항은 이미 관측된 ξ_n 이므로 그대로 ξ_n 이다. 둘째 항은 어떻게 될까? η_{n+1} 은 과거 변수들이 생성하는 $\mathcal{F}_n$ 과 independent이므로

$$E(\eta_{n+1} | \mathcal{F}_n) = E\eta_{n+1} = 0.$$

따라서 conditional expectation은 $\xi_n + 0 = \xi_n$ a.s.이다. independence는 과거를 조건으로 준 expectation을 보통 expectation으로 바꾸는 단계에, 평균 0은 그 나머지 항을 없애는 단계에 쓰였다. $\square$

관측이 늘어날 때의 예측값

이번에는 independent인 증가량을 직접 주지 않고, 같은 random variable에 대한 예측을 갱신해보자.

Example 3.4. $\xi \in L^1$ 이고 $(\mathcal{F}_n)$ 이 filtration이면

$$\xi_n = E(\xi | \mathcal{F}_n)$$

은 $(\mathcal{F}_n)$ 에 대한 martingale이다.

시점 n 에는 $\mathcal{F}_n$ 만큼의 정보를 알고 있다. 새로운 관측이 생기면 ξ 에 대한 예측도 달라질 수 있다. 하지만 현재 정보로 다음 예측값을 평균 내면 지금의 예측값으로 돌아온다.

Proof. conditional expectation의 정의에 의해 ξ_n 은 integrable하고 $\mathcal{F}_n$ -measurable이다. 남은 조건에서는 먼저 ξ_{n+1} 의 정의를 대입하고 tower property를 쓴다.

$$\begin{aligned} E(\xi_{n+1} | \mathcal{F}_n) &= E(E(\xi | \mathcal{F}_{n+1}) | \mathcal{F}_n) \\ &= E(\xi | \mathcal{F}_n) = \xi_n \quad \text{a.s.} \end{aligned}$$

$\mathcal{F}_n \subseteq \mathcal{F}_{n+1}$ 이므로 두 번 조건을 주면 더 작은 sigma-field에 대한 conditional expectation이 남는다. 이 예에서는 independence를 쓰지 않았다. $\square$

martingale의 expectation은 일정하다

Exercise 3.3. martingale (ξ_n) 에 대해

$$E\xi_n = E\xi_1 \quad \text{모든 } n \geq 1$$

임을 보여라.

Proof. martingale 등식에 expectation을 취하고 전체 expectation 보존 성질을 쓰면

$$E\xi_n = E(E(\xi_{n+1} | \mathcal{F}_n)) = E\xi_{n+1}.$$

마지막 성질은 conditional expectation 정의에서 시험 사건을 Ω 로 택한 적분 등식이다. 한 단계마다 expectation이 같으므로 귀납적으로 모든 시점에서 $E\xi_1$ 과 같다. $\square$

random variable의 실현값은 시간에 따라 변해도 expectation은 일정하다. 그 상수는 양수일 수도, 음수일 수도, 0일 수도 있다. 초기 누적 수익이 0인 공정한 게임은 매 고정 시점에서 기대수익이 0이다. 초기 자산까지 포함한 과정이라면 expectation은 그 초기값으로 유지된다. 이것이 매 경로의 자산이 일정하다는 주장은 아니다.

natural filtration으로 정보를 줄여도 되는가

Exercise 3.4. (ξ_n) 이 $(\mathcal{F}_n)$ 에 대한 martingale이면 자신의 natural filtration

$$\mathcal{G}_n = \sigma(\xi_1, \dots, \xi_n)$$

에 대해서도 martingale임을 보여라.

여기에는 filtration이 두 개 있다. 주어진 $\mathcal{F}_n$ 과 관측값들 자체가 생성한 $\mathcal{G}_n$ 은 같을 필요가 없다. 하지만 지난 시간의 최소성에 의해 $\mathcal{G}_n \subseteq \mathcal{F}_n$ 이다.

Proof. 변수 자체를 바꾸지 않았으므로 integrability는 그대로이다. natural filtration의 정의에 의해 ξ_n 은 $\mathcal{G}_n$ -measurable이다. 포함관계와 tower property로

$$\begin{aligned} E(\xi_{n+1} | \mathcal{G}_n) &= E(E(\xi_{n+1} | \mathcal{F}_n) | \mathcal{G}_n) \\ &= E(\xi_n | \mathcal{G}_n) = \xi_n \quad \text{a.s.} \end{aligned}$$

를 얻는다. 두 번째 줄의 첫 등식에는 원래 filtration에 대한 martingale 성질을, 마지막 등식에는 $\mathcal{G}_n$ -measurability를 사용했다. $\square$

앞으로 filtration을 생략해 말할 때는 natural filtration을 기본으로 생각할 수 있다. filtration을 명시한 명제에서는 그 filtration을 계속 사용하자.

symmetric random walk: 제곱에서 시간을 빼기

Exercise 3.5 (Symmetric Random Walk). independent인 random variable (η_n) 이

$$P\{\eta_n = 1\} = P\{\eta_n = -1\} = \frac{1}{2}$$

를 만족한다고 하자. symmetric random walk를

$$\xi_0 = 0, \quad \xi_n = \sum_{k=1}^n \eta_k$$

로 정의한다. 이때 $\xi_n^2 - n$ 이 filtration

$$\mathcal{F}_0 = \{\emptyset, \Omega\}, \quad \mathcal{F}_n = \sigma(\eta_1, \dots, \eta_n) \quad (n \geq 1)$$

에 대한 martingale임을 보여라.

실수축의 원점에서 시작하여 매번 오른쪽 또는 왼쪽으로 한 칸씩 움직이는 모습을 생각하면 된다. 오른쪽과 왼쪽의 확률이 각각 1/2이고, 새로운 방향은 이전 걸음들과 independent이다. η_n 은 한 걸음의 변화량이고 ξ_n 은 n 번 움직인 뒤의 위치이다. 시점 n 의 위치는 $-n$ 과 n 사이에 있다.

위치 자체는 Example 3.3의 martingale이다. 이제 제공한 위치를 살펴보면 매 단계에 평균적으로 1만큼의 증가분이 생기고, 그만큼인 n 을 빼면 다시 martingale이 된다. 이 말을 계산으로 확인하자.

Proof. 각 η_k 는 almost surely ± 1 이므로

$$|\xi_n| \leq n, \quad |\xi_n^2 - n| \leq n^2 + n \quad \text{a.s.}$$

이다. n 마다 유한한 상계가 있으므로 integrable하고, $\mathcal{F}_n$ -measurability도 정의에서 따른다. 모든 n 에 공통인 하나의 유한 상계를 주장하는 것은 아니다.

새 걸음 η_{n+1} 은 $\mathcal{F}_n$ 과 independent이다. 또

$$E\eta_{n+1} = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot (-1) = 0, \quad \eta_{n+1}^2 = 1 \quad \text{a.s.}$$

이므로 $E(\eta_{n+1} | \mathcal{F}_n) = 0$, $E(\eta_{n+1}^2 | \mathcal{F}_n) = 1$ a.s.이다. 이제 제곱을 전개하면

$$\begin{aligned} E(\xi_{n+1}^2 - (n+1) | \mathcal{F}_n) &= E((\xi_n + \eta_{n+1})^2 | \mathcal{F}_n) - (n+1) \\ &= \xi_n^2 + 2\xi_n E(\eta_{n+1} | \mathcal{F}_n) + E(\eta_{n+1}^2 | \mathcal{F}_n) - (n+1) \\ &= \xi_n^2 + 2\xi_n \cdot 0 + 1 - (n+1) \\ &= \xi_n^2 - n \quad \text{a.s.} \end{aligned}$$

ξ_n 과 ξ_n^2 는 현재 정보로 아는 값이다. 특히 교차항에서 ξ_n 을 밖으로 꺼낼 수 있고, 이 예에서는 bounded이므로 곱의 integrability도 확보된다. 새 걸음의 제곱을 밖으로 꺼낸 것이 아니라 그 conditional expectation을 1로 계산한 것이다. 교차항은 평균 0 때문에 사라지고, 제곱항의 1은 시간 증가분 1과 상쇄된다. $\square$

이 보정항 n 은 이후에 중요한 의미를 갖는다. 방금 증명한 과정은 시점 0에서 0이므로 expectation 보존에 의해

$$E(\xi_n^2 - n) = 0, \quad E\xi_n^2 = n.$$

따라서 제곱평균의 제곱근은 $\sqrt{n}$ 이다. random walk의 규모를 이야기할 때 $\sqrt{n}$ 이 등장하는 이유를 여기서 볼 수 있다. 이것이 모든 경로가 매번 $\sqrt{n}$ 만큼 떨어져 있다는 뜻은 아니다.

같은 보행으로 연습하기

Exercise 3.6. 위 symmetric random walk에 대해

$$\zeta_n = (-1)^n \cos(\pi \xi_n), \quad n \geq 0$$

가 같은 filtration에 대한 martingale임을 보여라.

여러 예제에서 세 조건을 확인해 보았으니, 이 증명은 직접 해 보자. 이제 공정성의 등식을 부등식으로 바꾼 정의로 넘어가자.

conditional expectation이 증가하거나 감소하는 경우

현실의 게임이 모두 공정한 것은 아니다. 현재 정보로 예상하는 다음 값이 지금보다 클 수도 있고 작을 수도 있다. integrability와 adaptedness는 그대로 두고 세 번째 조건을 바꾼다.

Definition (submartingale과 supermartingale). (ξ_n) 이 integrable한 random variable들로 이루어지고 $(\mathcal{F}_n)$ 에 adapted라고 하자. 모든 n 에 대해

$$E(\xi_{n+1} | \mathcal{F}_n) \geq \xi_n \quad \text{a.s.}$$

이면 submartingale,

$$E(\xi_{n+1} | \mathcal{F}_n) \leq \xi_n \quad \text{a.s.}$$

이면 supermartingale이라고 한다.

이름의 느낌만으로 방향을 외우면 헷갈릴 수 있다. Supermartingale의 “super”가 돈을 더 번다는 뜻은 아니다. 이름보다 부등식을 먼저 보자. 현재 값이 다음 값의 conditional expectation보다 위에 놓인다. 수익 과정으로 해석하면 불리한 방향이다. Submartingale은 반대로 다음 conditional expectation이 현재 값 이상인 유리한 방향이다. 이 명명에는 superharmonic function의 부호 관례와의 관련도 있지만, 여기서는 위의 부등식을 정의로 사용하면 된다.

두 경우 모두 실제 경로가 늘 감소하거나 늘 증가할 필요는 없다. 비교하는 대상은 다음 실현값 자체가 아니라 현재 정보에 대한 다음 값의 conditional expectation이다.

convex function을 적용하면 submartingale이 된다

앞 장에서 conditional expectation에 convex function을 적용하면 등식 대신 Jensen's inequality를 얻었다. martingale에도 같은 방법을 써 보자.

Exercise 3.7. (ξ_n) 이 $(\mathcal{F}_n)$ 에 대한 martingale이고 모든 n 에 대해 $\xi_n \in L^2$ 라고 하자. 그러면 (ξ_n^2) 은 같은 filtration에 대한 submartingale이다.

Proof. $\xi_n \in L^2$ 는 $E\xi_n^2 < \infty$ 라는 뜻이므로 제공한 변수의 integrability를 확보한다. 또한 $x \mapsto x^2$ 는 연속인 Borel function이므로 ξ_n^2 도 $\mathcal{F}_n$ -measurable이다.

마지막으로 convex function x^2 에 대한 conditional Jensen's inequality를 쓴다.

$$E(\xi_{n+1}^2 | \mathcal{F}_n) \geq (E(\xi_{n+1} | \mathcal{F}_n))^2 = \xi_n^2 \quad \text{a.s.}$$

Jensen에 필요한 ξ_{n+1} 의 integrability는 martingale 조건에서, 그 제공의 integrability는 추가한 L^2 조건에서 나온다. 마지막 등식은 원래 과정의 martingale 성질이다. $\square$

제공만 가능한 것은 아니다. 유한값 convex function $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 에 대해 모든 n 에서 $\varphi(\xi_n) \in L^1$ 이면 같은 계산으로

$$E(\varphi(\xi_{n+1}) | \mathcal{F}_n) \geq \varphi(E(\xi_{n+1} | \mathcal{F}_n)) = \varphi(\xi_n) \quad \text{a.s.}$$

이다. 유한값 convex function은 연속이므로 합성의 measurability도 성립한다. 따라서 $(\varphi(\xi_n))$ 은 같은 filtration에 대한 submartingale이다.

3.4 우연에 따른 게임과 전략

지금까지는 게임 자체가 공정한지, 유리한지, 불리한지를 나타내는 모형을 정의했다. 이제 판마다 거는 금액을 바꾸는 전략을 생각해 보자. 공정한 게임에서도 이전 결과를 보고 금액을 잘 바꾸면 기대수익을 얻을 수 있을까?

곧 볼 명제는 일정한 조건 아래에서, 과거 정보를 사용해 베팅 금액을 바꾸어도 매 고정된 유한 시점의 기대수익은 0이라는 결과이다. 한편 횟수를 제한하지 않고 신용도 무제한으로 허용하면 어떤 전략이 가능한지도 이후에 살펴보자. 여기서는 먼저 각 유한 시점에서 성립하는 명제를 정확히 세우자.

결과를 보기 전에 금액을 정한다

Definition (previsible인 열). filtration $(\mathcal{F}_n)_{n \geq 0}$ 에 대해, 모든 $n \geq 1$ 에서 α_n 이 $\mathcal{F}_{n-1}$ -measurable이면 (α_n) 이 previsible하다고 한다.

α_n 은 n 번째 판에 거는 금액이고, (α_n) 을 gambling strategy라고 부른다. 룰렛이나 주사위 게임을 여러 번 한다고 생각해 보자. 어떤 판에는 많은 돈을 걸고, 어떤 판에는 아예 참여하지 않을 수 있다. $\alpha_n = 0$ 은 그 판을 건너뛴다는 뜻이다. 수학적 모형에서는 음수 금액도 허용할 수 있다.

왜 $\mathcal{F}_n$ 이 아니라 $\mathcal{F}_{n-1}$ 일까? n 번째 금액을 정할 때는 앞의 $n-1$ 번 결과만 보았다. 이번 결과가 나온 다음에 그 결과를 이용해 금액을 정할 수는 없다. previsible이라는 조건은 바로 이 시간 순서를 표현한다. adapted라는 조건에서는 현재 정보로 현재 값을 알면 됐다. 지금은 더 이른 정보가 필요하다. 한 단계 전의 정보만으로 이번 금액을 정할 수 있어야 한다.

단위 금액을 걸었을 때 n 번째 순수익을 η_n 이라고 쓰고

$$\xi_0 = 0, \quad \xi_n = \sum_{k=1}^n \eta_k, \quad \mathcal{F}_n = \sigma(\eta_1, \dots, \eta_n), \quad \mathcal{F}_0 = \{\emptyset, \Omega\}$$

으로 두자. ξ_n 은 단위 금액으로 계속 참여했을 때의 누적 수익이다. $\xi_0 = 0$ 은 시작 시 누적 수익을 0으로 잡았다는 뜻이다. 각 ξ_n 은 integrable하다고 하고, conditional expectation에 따라 다음과 같이 부른다.

$$\begin{aligned} E(\xi_n | \mathcal{F}_{n-1}) &= \xi_{n-1} & \text{a.s.} & \text{공정한 게임 (fair),} \\ E(\xi_n | \mathcal{F}_{n-1}) &\geq \xi_{n-1} & \text{a.s.} & \text{유리한 게임 (favorable),} \\ E(\xi_n | \mathcal{F}_{n-1}) &\leq \xi_{n-1} & \text{a.s.} & \text{불리한 게임 (unfavorable).} \end{aligned}$$

각각 martingale, submartingale, supermartingale에 대응한다.

전략 (α_n) 을 사용했을 때의 실제 누적 수익을 ζ_n 으로 구별해 쓰면

$$\zeta_0 = 0, \quad \zeta_n = \sum_{k=1}^n \alpha_k (\xi_k - \xi_{k-1}).$$

$\xi_k - \xi_{k-1} = \eta_k$ 가 그 판의 단위 금액당 수익이다. 여기에 α_k 를 곱하면 선택한 금액의 수익이고, 이를 더한 것이 전체 수익이다. ζ_n 자체는 기대수익이 아니라 아직 무작위인 누적 수익이다.

bounded인 previsible 전략은 공정성을 보존한다

Proposition 3.1. (α_n) 이 previsible하고 각 α_n 이 bounded라고 하자. 위에서 정의한 (ζ_n) 에 대해 다음이 성립한다.

1. (ζ_n) 이 martingale이면 (ζ_n) 도 같은 filtration에 대한 martingale이다.
2. 추가로 모든 n 에 대해 $\alpha_n \geq 0$ a.s.이면, (ξ_n) 이 supermartingale일 때 (ζ_n) 도 supermartingale이고, (ξ_n) 이 submartingale일 때 (ζ_n) 도 submartingale이다.

공정한 게임에서는 이런 전략을 사용해도 결과가 martingale로 남는다. 따라서 $\zeta_0 = 0$ 이면 매 고정된 유한 n 에서 $E\zeta_n = 0$ 이다. 전략으로 게임을 이길 수 없다는 말을 이 명제에서는 이 의미로 이해하면 된다. 개별 경로에서 돈을 버는 일이 없다는 말은 아니다.

왜 각 금액이 bounded여야 할까? 곧 볼 증명에서는 이 조건을 사용해 전략을 적용한 수익도 integrable하다는 것을 보인다. 여기서는 각 n 에 대해 유한한 상계가 있으면 되고, 모든 n 에 공통인 하나의 상계를 요구하지 않는다. 따라서 이 가정을 곧바로 전체 기간에 걸친 총 신용 한도와 동일시하지 말자. 비음성은 두 번째 결론의 부등식 방향을 보존하는 데 필요하다.

Proof. 먼저 adaptedness를 확인하자. $k \leq n$ 이면 α_k 는 $\mathcal{F}_{k-1}$ -measurable이고, $\xi_k - \xi_{k-1}$ 는 $\mathcal{F}_k$ -measurable이다. 이 sigma-field들은 모두 $\mathcal{F}_n$ 에 포함되므로 각 곱과 그 유한합 ζ_n 은 $\mathcal{F}_n$ -measurable이다.

다음으로 integrability이다. $\|\alpha_k\|_\infty$ 를 $|\alpha_k|$ 의 almost sure 상계 중 가장 작은 값으로 쓰면

$$\begin{aligned} E|\alpha_k(\xi_k - \xi_{k-1})| &\leq \|\alpha_k\|_\infty E|\xi_k - \xi_{k-1}| \\ &\leq \|\alpha_k\|_\infty (E|\xi_k| + E|\xi_{k-1}|) < \infty. \end{aligned}$$

각 항이 integrable하므로 그 유한합 ζ_n 도 integrable하다.

마지막 한 판의 수익을 분리하면

$$\zeta_n = \zeta_{n-1} + \alpha_n(\xi_n - \xi_{n-1}).$$

$\zeta_{n-1}, \alpha_n, \xi_{n-1}$ 은 모두 $\mathcal{F}_{n-1}$ -measurable이다. bounded 인자를 밖으로 꺼내는 성질과 linearity를 적용하면

$$E(\zeta_n | \mathcal{F}_{n-1}) = \zeta_{n-1} + \alpha_n(E(\xi_n | \mathcal{F}_{n-1}) - \xi_{n-1}) \quad \text{a.s.}$$

martingale인 경우 괄호가 0이므로 결과는 ζ_{n-1} 이다. 이것으로 세 조건을 모두 확인했다.

supermartingale이면 괄호가 0 이하이다. $\alpha_n \geq 0$ 이므로 곱도 0 이하이고

$$E(\zeta_n | \mathcal{F}_{n-1}) \leq \zeta_{n-1} \quad \text{a.s.}$$

이다. submartingale이면 괄호가 0 이상이므로 같은 논리로 반대 부등식을 얻는다. 만약 금액의 부호를 제한하지 않으면 음수를 곱할 때 방향이 뒤집힐 수 있어 이 두 결론을 그대로 주장할 수 없다. $\square$

공정성의 보존에는 이전 정보로 금액을 정한다는 조건이 정확히 사용되었다. 다음에는 무제한 신용과 계속되는 시행을 생각했을 때 흥미로운 전략이 어떻게 나타나는지 살펴보자. 지금까지 얻은 결론은 어디까지나 각각의 유한 시점에 대한 것이다.